



MINISTÉRIO DA EDUCAÇÃO
UNIVERSIDADE FEDERAL RURAL DA AMAZÔNIA
INSTITUTO CIBERESPACIAL
CURSO DE GRADUAÇÃO EM ENGENHARIA AMBIENTAL E ENERGIAS
RENOVÁVEIS

NADELLY GAMA DA SILVA

O USO DE INTELIGÊNCIA ARTIFICIAL PARA
CLASSIFICAÇÃO DE CORTE RASO EM IMAGENS DE
SATÉLITE NO ESTADO DO PARÁ

BELÉM, PA

2026

Nadelly Gama Da Silva

**O USO DE INTELIGÊNCIA ARTIFICIAL PARA
CLASSIFICAÇÃO DE CORTE RASO EM IMAGENS DE
SATÉLITE NO ESTADO DO PARÁ**

Trabalho de Conclusão de Curso apresentado no curso de Engenharia Ambiental e Energias Renováveis da Universidade Federal Rural da Amazônia, como requisito básico para a atividade Trabalho de Conclusão de Curso II.

Orientador: Prof. Dr. Wallace de Sousa Elias.

**BELÉM, PA
2026**

Dados Internacionais de Catalogação na Publicação (CIP)
Bibliotecas da Universidade Federal Rural da Amazônia
Gerada automaticamente mediante os dados fornecidos pelo(a) autor(a)

S586u Silva, Nadelly Gama da
O uso de inteligência artificial para a classificação de corte raso no estado do Pará /
Nadelly Gama da Silva. - 2026.
66 f. : il. color.

Trabalho de Conclusão de Curso (Graduação) - Curso de Engenharia Ambiental e
Energias Renováveis, Campus Universitário de Belém, Universidade Federal Rural Da
Amazônia, Belém, 2026.

Orientador: Prof. Dr. Wallace de Sousa Elias

1. Inteligência artificial. 2. Sensoriamento remoto. 3. Desmatamento. 4. Amazônia. 5.
Random forest. I. Elias, Wallace de Sousa, orient. II. Título

CDD 621.3678

NADELLY GAMA DA SILVA

**O USO DE INTELIGÊNCIA ARTIFICIAL PARA
CLASSIFICAÇÃO DE CORTE RASO EM IMAGENS DE
SATÉLITE NO ESTADO DO PARÁ**

Trabalho de Conclusão de Curso apresentado ao Curso de Engenharia Ambiental e Energias Renováveis, da Universidade Federal Rural da Amazônia (UFRA), como parte dos requisitos para obtenção do título de Graduado.

Orientador(a): Prof. Dr. Wallace De Sousa Elias

Aprovado em: 11 de fevereiro de 2026.

Banca Examinadora:

Documento assinado digitalmente



WALACE DE SOUSA ELIAS

Data: 17/03/2026 11:12:31-0300

Verifique em <https://validar.iti.gov.br>

Prof. Dr. Wallace de Sousa Elias
Universidade Federal Rural da Amazônia

Documento assinado digitalmente



CAROLINA DA SILVA GONCALVES

Data: 17/03/2026 15:20:40-0300

Verifique em <https://validar.iti.gov.br>

Profª. Drª Carolina da Silva Gonçalves
Universidade Federal Rural da Amazônia

Documento assinado digitalmente



TABILLA VERENA DA SILVA LEITE

Data: 17/03/2026 13:36:06-0300

Verifique em <https://validar.iti.gov.br>

Profª. Drª Tabilla Verena da Silva Leite
Universidade Federal Rural da Amazônia

AGRADECIMENTOS

Este trabalho representa mais do que a conclusão de uma etapa acadêmica, pois carrega a trajetória e o apoio de muitos, os quais contribuíram, direta ou indiretamente, para que este momento fosse possível.

Agradeço profundamente à minha família, por cada incentivo, gesto de apoio e palavra de confiança, essenciais para continuar em frente, mesmo nos momentos mais desafiadores.

Agradeço, especialmente, à minha avó paterna, que; mesmo sem ter tido a oportunidade de concluir o ensino fundamental, num tempo em que muitas meninas não tinham a permissão de permanecer na escola, ela sempre me incentivou a estudar.

Aos meus amigos e amigas, agradeço pela presença ao longo dessa jornada, pelo apoio nos momentos de dúvida e por tornarem o caminho mais leve.

Agradeço de forma especial ao meu orientador, pela orientação, paciência e confiança durante o processo, fundamentais para a construção desta pesquisa e para meu amadurecimento acadêmico.

Também agradeço às professoras da banca examinadora, pela disponibilidade em avaliar esta dissertação e pelas contribuições que certamente a aprimoraram.

Por fim, registro minha admiração às mulheres que vieram antes de mim e às que caminham ao meu lado na ciência e na universidade.

E essa não é uma conquista individual, é coletiva, construída por gerações que abriram caminhos e ampliaram os espaços no conhecimento.

Espero que este projeto seja uma pequena contribuição para a trajetória de construção de saberes e transformação na Amazônia.

A todos que fizeram parte dessa jornada, meu sincero agradecimento.

“Não há defesa da floresta sem as pessoas que vivem nela e sem o conhecimento que nasce do território” (Becker, 2005).

RESUMO

Este trabalho tem como objetivo desenvolver e validar um modelo de classificação de imagens de satélite, baseado no algoritmo Random Forest, para a identificação de áreas de corte raso no estado do Pará. O estudo foi realizado na região amazônica paraense, utilizando imagens do satélite Landsat 8 de nível 2, obtidas via Google Earth Engine. A metodologia utilizada foi quantitativa e aplicada, compreendendo a aquisição e pré-processamento de imagens, a coleta de amostras georreferenciadas das classes vegetação e corte raso, o cálculo de índices espectrais (NBR, NDVI, NDMI) e o treinamento e avaliação do modelo de aprendizado de máquina. A amostragem foi realizada por meio de pontos aleatórios sobre imagens Landsat, utilizando polígonos de referência do PRODES. Os resultados apresentaram um desempenho excepcional do modelo, com acurácia global de 98,37%, precisão de 97,67% para a classe corte raso e recall de 98,75% para vegetação. A análise de importância das variáveis revelou que os índices NBR (relacionado a queimadas) e NDMI (sensível à umidade) foram os mais discriminativos para a detecção do desmatamento na área estudada. Teve-se como conclusão de que o modelo Random Forest constitui uma ferramenta acessível, ágil e de alta precisão para o monitoramento ambiental local, demonstrando potencial para subsidiar ações de fiscalização. O estudo evidencia a necessidade de articular o conhecimento técnico-algorítmico com uma perspectiva crítica sobre as limitações sociais e metodológicas do uso do sensoriamento remoto no monitoramento ambiental.

Palavras-chave: inteligência artificial; sensoriamento remoto; desmatamento; Amazônia; Pará; Random Forest.

ABSTRACT

This work aimed to develop and validate a satellite image classification model, based on the Random Forest algorithm, for identifying clear-cut areas in the state of Pará. The study was conducted in the Amazon region of Pará, using images from the Landsat 8 satellite level 2, obtained via Google Earth Engine. The methodology was quantitative and applied, comprising image acquisition and preprocessing, collection of georeferenced samples for the vegetation and clear-cut classes, calculation of spectral indices (NBR, NDVI, NDMI), and training and evaluation of the machine learning model. Sampling was performed using random points on Landsat images, based on PRODES reference polygons. The results showed exceptional model performance, with an overall accuracy of 98.37%, precision of 97.67% for the clear-cut class, and recall of 98.75% for vegetation. The variable importance analysis revealed that the NBR (related to burning) and NDMI (sensitive to moisture) indices were the most discriminative for detecting deforestation in the study area. It was concluded that the Random Forest model constitutes an accessible, agile, and high-precision tool for local environmental monitoring, demonstrating potential to support inspection actions. The study also highlighted the need to integrate technical-algorithmic knowledge with critical perspectives on the epistemological and social limitations inherent to remote sensing monitoring.

Keywords: artificial intelligence; remote sensing; deforestation; Amazon; Pará; Random Forest.

LISTA DE ILUSTRAÇÕES

Figura 1 - Análise multitemporal de desmatamento.....	18
Figura 2 - N-árvores para escolha da decisão final através de indicação (voto).....	23
Figura 3 - Mapa estadual de incrementos de desmatamento na Amazônia de 2008 até 2024.....	26
Figura 4 - Mapa municipal de incrementos de desmatamento na Amazônia de 2008 até 2024.....	26
Figura 5 - Fluxograma metodológico.	28
Figura 6 - Mapa da região amostral.	32
Figura 7 - Validação cruzada	40
Figura 8 - Importância relativa das variáveis no modelo Random Forest.	43
Figura 9 - Matriz de confusão	45
Figura 10 - Mapa de classificação de corte raso.....	47
Figura 11 - Mosaico de classificação de corte raso.	48
Figura 12 - Distribuições espaciais encontradas pelo modelo.	49

LISTA DE TABELAS

Tabela 1 - Bandas escolhidas.....	30
Tabela 2 - Hiperparâmetros do Random Forest configurados.	34
Tabela 3 - Distribuição das amostras por classe e conjunto de dados.	39
Tabela 4 - Desempenho do modelo Random Forest nos dados de teste.	41
Tabela 5 - Ranking de importância das variáveis.	43
Tabela 6 - Áreas classificadas na região de estudo.....	48

LISTA DE ABREVIATURAS E SIGLAS

DETER	Sistema de Detecção de Desmatamento em Tempo Real
DN	<i>Digital Number</i>
GEE	Google Earth Engine
IA	Inteligência Artificial
INPE	Instituto Nacional de Pesquisas Espaciais
NBR	<i>Normalized Burn Ratio</i>
NDFI	<i>Normalized Difference Fraction Index</i>
NDMI	<i>Normalized Difference Moisture Index</i>
NDVI	<i>Normalized Difference Vegetation Index</i>
NIR	<i>Near Infrared</i> (Infravermelho Próximo)
OLI	<i>Operational Land Imager</i>
PRODES	Projeto de Monitoramento do Desmatamento na Amazônia Legal por Satélite
RF	Random Forest
SAD	Sistema de Alerta de Desmatamento
SIG	Sistema de Informação Geográfica
SWIR	<i>Short Wave Infrared</i> (Infravermelho de Ondas Curtas)
USGS	<i>United States Geological Survey</i>

SUMÁRIO

1 INTRODUÇÃO.....	13
2 DESENVOLVIMENTO	14
2.1 Fundamentação teórica	14
2.1.1 Sensoriamento remoto aplicado ao monitoramento ambiental.....	15
2.1.2 Sistemas de monitoramento do desmatamento na Amazônia.....	16
2.1.3 Os aspectos socioambientais e políticos do desmatamento na Amazônia ..	18
2.1.4 O papel do sensoriamento remoto como tecnologia de vigilância ambiental	20
2.1.5 O uso do algoritmo Random Forest na análise e na produção de informações geoespaciais	22
2.1.6 Síntese teórica: por uma abordagem interdisciplinar para o monitoramento amazônico.	24
2.2 Justificativa	25
3 OBJETIVOS	27
3.1 Geral.....	27
3.2 Específicos	27
4 METODOLOGIA DA PESQUISA	28
4.1 Aquisição das imagens.....	29
4.1.1 Características dos dados e escala de reflectância.....	30
4.2 Coleta de amostras.....	31
4.3 Treinamento e avaliação do modelo	33
4.3.1 Configuração dos hiperparâmetros do algoritmo Random Forest	34
4.3.2 Avaliação do modelo	35
5 RESULTADOS E DISCUSSÕES	39
5.1 Análise do desempenho do modelo.....	39
5.2 Análise da importância das variáveis.....	42
5.3 Análise da matriz de confusão	44

5.4 Mapeamento e análise espacial	46
5.5 Limitações técnicas e metodológicas	50
6 CONCLUSÃO	53
REFERÊNCIAS	55
APÊNDICES	60
APÊNDICE A - <i>Dataset</i>	60
APÊNDICE B - <i>Script</i> em Python para treinamento e aplicação do modelo Random Forest.	61
APÊNDICE C – <i>Script</i> para aquisição de imagens no Google Earth Engine.	65

1 INTRODUÇÃO

O avanço do desmatamento na Amazônia Legal representa um dos principais desafios socioambientais do Brasil, devido aos impactos que provoca sobre o clima, a biodiversidade e os serviços ecossistêmicos em escala regional e global. Dados do Instituto Nacional de Pesquisas Espaciais (INPE) indicam que, entre 1988 e 2024, mais de 800 mil km² de floresta amazônica foram desmatados, área equivalente ao território de países como a Turquia.

No estado do Pará, historicamente um dos principais focos de perda florestal, os incrementos de desmatamento ultrapassam 54 mil km² desde 2008, com municípios como Altamira, São Félix do Xingu e Novo Progresso frequentemente figurando entre os mais desmatados da Amazônia (INPE, 2024; Beckmann et al., 2024).

Nesse contexto, o monitoramento da cobertura da terra tornou-se fundamental para compreender a dinâmica espacial do desmatamento e subsidiar ações de fiscalização ambiental. O uso de geotecnologias, como o sensoriamento remoto e os sistemas de informação geográfica (SIG), permite acompanhar grandes extensões territoriais de forma contínua, identificando alterações na cobertura do solo e produzindo informações estratégicas para a gestão ambiental.

No Brasil, sistemas operacionais como o PRODES (Projeto de Monitoramento do Desmatamento na Amazônia Legal por Satélite) e o DETER (Sistema de Detecção de Desmatamento em Tempo Real) utilizam imagens de satélite para detectar e comunicar áreas desmatadas, auxiliando órgãos públicos na realização de operações de fiscalização e no planejamento territorial (INPE, 2022; Alencar et al., 2020).

Nos últimos anos, o avanço das técnicas de inteligência artificial tem ampliado as possibilidades de análise de dados provenientes do sensoriamento remoto. Métodos de aprendizado de máquina permitem identificar padrões complexos em grandes volumes de dados espectrais, contribuindo para aumentar a precisão e a automatização dos processos de classificação de uso e cobertura da terra (Belgiu; Drăguț, 2016; Zhu et al., 2017).

Essas abordagens têm sido amplamente aplicadas em estudos ambientais, especialmente em regiões tropicais, onde a heterogeneidade da vegetação e as condições atmosféricas podem dificultar a aplicação de métodos tradicionais de classificação.

Apesar dos avanços proporcionados pelos sistemas nacionais de monitoramento, ainda existem desafios relacionados à análise em escalas regionais e à adaptação de métodos automatizados para contextos específicos. Dessa forma, torna-se relevante o desenvolvimento de modelos de classificação baseados em inteligência artificial que utilizem dados abertos e metodologias replicáveis, capazes de apoiar iniciativas locais de monitoramento ambiental.

Nesse contexto, o presente trabalho tem como objetivo desenvolver e validar um modelo de classificação baseado no algoritmo Random Forest para identificar áreas de corte raso no estado do Pará a partir de imagens de satélite.

2 DESENVOLVIMENTO

O desenvolvimento do presente trabalho organiza-se em três capítulos principais que seguem uma sequência lógica e progressiva: a fundamentação teórica até a justificativa da pesquisa. Esta estrutura visa construir, etapa por etapa, o arcabouço conceitual e prático necessário para o enfrentamento do problema de pesquisa proposto.

Inicialmente, será apresentada a fundamentação teórica, que estabelece as bases científicas sobre o fenômeno do desmatamento por corte raso na Amazônia, a evolução das técnicas de monitoramento por sensoriamento remoto e os princípios dos algoritmos de inteligência artificial aplicados à classificação de imagens, com ênfase no Random Forest.

Em seguida, na justificativa, serão articuladas as razões que tornam esta pesquisa relevante tanto do ponto de vista acadêmico quanto operacional, posicionando-a como uma resposta tecnológica acessível a um desafio ambiental urgente no estado do Pará.

Por fim, a metodologia detalhará o caminho percorrido para transformar o referencial teórico em resultados práticos, descrevendo de forma reproduzível todas as etapas, desde a aquisição dos dados até a validação do modelo proposto.

2.1 Fundamentação teórica

A fundamentação teórica constitui o alicerce conceitual que sustenta a

investigação proposta, situando-a dentro do *corpus* de conhecimento científico existente. Nesse ínterim, este capítulo estrutura-se em três eixos inter-relacionados que, em conjunto, fornecem o quadro referencial necessário para compreender e operacionalizar o monitoramento de corte raso por meio de inteligência artificial:

1. Os aspectos socioambientais e políticos do desmatamento na Amazônia;
2. O papel do sensoriamento remoto como ferramenta de monitoramento e fiscalização ambiental; e
3. O uso do algoritmo Random Forest na análise e na produção de informações geoespaciais.

2.1.1 Sensoriamento remoto aplicado ao monitoramento ambiental

O monitoramento sistemático do desmatamento na Amazônia brasileira é realizado por meio de diferentes sistemas baseados em sensoriamento remoto, desenvolvidos por instituições públicas e organizações da sociedade civil. Esses sistemas utilizam imagens de satélite para identificar alterações na cobertura da terra e gerar informações que apoiam ações de fiscalização ambiental e políticas públicas voltadas ao controle do desmatamento (INPE, 2022; Souza et al., 2020).

Entre os principais sistemas utilizados no Brasil destaca-se o PRODES (Projeto de Monitoramento do Desmatamento na Amazônia Legal por Satélite), desenvolvido pelo Instituto Nacional de Pesquisas Espaciais (INPE).

Criado em 1988, o PRODES realiza o mapeamento anual das áreas de corte raso na Amazônia Legal por meio da análise de imagens de satélite de média resolução espacial, principalmente da série Landsat. O sistema produz estimativas oficiais da taxa anual de desmatamento e constitui a principal referência para o acompanhamento da perda de cobertura florestal na região amazônica (INPE, 2022; Câmara et al., 2006).

Complementarmente, o DETER (Sistema de Detecção de Desmatamento em Tempo Real) foi desenvolvido com o objetivo de apoiar ações de fiscalização ambiental. Diferentemente do PRODES, que produz dados consolidados anuais, o DETER gera alertas frequentes a partir da análise de imagens de satélite, permitindo identificar rapidamente áreas com indícios de desmatamento ou degradação florestal.

Esses alertas são utilizados principalmente por órgãos de fiscalização ambiental para orientar operações de campo e ações de controle do desmatamento (INPE, 2022;

Assis et al., 2019).

Além dos sistemas governamentais, iniciativas independentes também contribuem para o monitoramento da floresta amazônica. O MapBiomas Alertas, por exemplo, integra diferentes bases de dados de detecção de desmatamento, incluindo alertas provenientes de sistemas como DETER e SAD, consolidando informações e validando os eventos de desmatamento identificados.

Essa plataforma permite rastrear alertas e verificar sua correspondência com autorizações ou embargos ambientais, ampliando a transparência e o acesso público às informações sobre desmatamento (MapBiomas, 2023).

Outro sistema relevante é o SAD (Sistema de Alerta de Desmatamento), desenvolvido pelo Instituto do Homem e Meio Ambiente da Amazônia (IMAZON). Esse sistema utiliza imagens de satélite para detectar mensalmente áreas de desmatamento e degradação florestal na Amazônia, fornecendo análises independentes sobre a dinâmica de perda florestal na região. Os dados produzidos pelo SAD têm sido amplamente utilizados em estudos científicos e relatórios de monitoramento ambiental (Souza et al., 2020).

A existência desses diferentes sistemas evidencia a importância das geotecnologias no monitoramento ambiental da Amazônia, permitindo a geração de informações estratégicas para o controle do desmatamento e para a formulação de políticas públicas voltadas à conservação da floresta (INPE, 2022; Souza et al., 2020).

2.1.2 Sistemas de monitoramento do desmatamento na Amazônia

O monitoramento sistemático do desmatamento na Amazônia brasileira é realizado por meio de diferentes sistemas baseados em sensoriamento remoto, desenvolvidos por instituições públicas e organizações da sociedade civil. Esses sistemas utilizam imagens de satélite para identificar alterações na cobertura da terra e gerar informações que apoiam ações de fiscalização ambiental e a formulação de políticas públicas voltadas ao controle do desmatamento (Almeida et al., 2021).

Entre os principais sistemas utilizados no Brasil destaca-se o PRODES (Projeto de Monitoramento do Desmatamento na Amazônia Legal por Satélite), desenvolvido pelo Instituto Nacional de Pesquisas Espaciais (INPE). Criado em 1988, o PRODES realiza o mapeamento anual das áreas de desmatamento por corte raso na Amazônia

Legal por meio da análise de imagens de satélite de média resolução espacial, principalmente da série Landsat.

O sistema produz estimativas oficiais da taxa anual de desmatamento e constitui a principal referência para o acompanhamento da perda de cobertura florestal na região amazônica (Almeida et al., 2021; INPE, 2022).

Complementarmente, o DETER (Sistema de Detecção de Desmatamento em Tempo Real) foi desenvolvido pelo INPE com o objetivo de apoiar ações de fiscalização ambiental. Diferentemente do PRODES, que produz dados consolidados anuais, o DETER gera alertas frequentes a partir da análise de imagens de satélite, permitindo identificar rapidamente áreas com indícios de desmatamento ou degradação florestal.

Esses alertas são utilizados principalmente por órgãos de fiscalização ambiental para orientar operações de campo e ações de controle do desmatamento (Almeida et al., 2021).

Além dos sistemas governamentais, iniciativas independentes também contribuem para o monitoramento da floresta amazônica. O MapBiomas Alertas, por exemplo, integra diferentes bases de dados de detecção de desmatamento, incluindo alertas provenientes de sistemas como DETER e SAD, consolidando informações e validando os eventos de desmatamento identificados.

A plataforma permite rastrear alertas e verificar sua correspondência com autorizações ambientais, embargos ou outras situações administrativas, ampliando a transparência e o acesso público às informações sobre desmatamento (MapBiomas, 2023).

Outro sistema relevante é o SAD (Sistema de Alerta de Desmatamento), desenvolvido pelo Instituto do Homem e Meio Ambiente da Amazônia (IMAZON). Esse sistema utiliza imagens de satélite para detectar mensalmente áreas de desmatamento e degradação florestal na Amazônia, fornecendo análises independentes sobre a dinâmica da perda florestal na região. Os dados produzidos pelo SAD são amplamente utilizados em estudos científicos e relatórios de monitoramento ambiental (Souza Jr. et al., 2020).


A existência desses diferentes sistemas evidencia a importância das geotecnologias no monitoramento ambiental da Amazônia, permitindo a geração de informações estratégicas para o controle do desmatamento e para o planejamento de políticas públicas voltadas à conservação da floresta.

2.1.3 Os aspectos socioambientais e políticos do desmatamento na Amazônia

O desmatamento por corte raso caracteriza-se pela remoção completa da cobertura florestal em um curto intervalo de tempo, sendo frequentemente seguido por queimadas e posterior conversão da área para outros usos, como pecuária ou agricultura (INPE, 2022).

Esse processo pode ser identificado em imagens de satélite pela mudança abrupta da assinatura espectral da vegetação para padrões associados a solo exposto ou vegetação degradada, como visto na Figura 1.

Figura 1 - Análise multitemporal de desmatamento.



Fonte: SEMAS-PA (2025).

A análise multitemporal permite observar a transformação progressiva da cobertura florestal em áreas abertas, evidenciando a dinâmica espacial do corte raso. Esse tipo de abordagem é amplamente utilizado no monitoramento ambiental por satélite, pois permite comparar imagens de diferentes períodos e identificar mudanças na cobertura da terra.

O desmatamento por corte raso na Amazônia não pode ser compreendido

apenas como um fenômeno biofísico de substituição de cobertura vegetal, visto que ele representa, antes, um processo sociotécnico complexo onde se entrelaçam políticas fundiárias, economias extrativas, conflitos territoriais e tecnologias de monitoramento (Hecht, 2011).

Por isso, a visão reducionista que trata o desmatamento como mera perda de árvores obscurece suas dimensões políticas e históricas, particularmente no estado do Pará, palco de intensos conflitos entre modelos de desenvolvimento antagônicos.

A obra clássica de Bunker (1985) sobre a economia política da Amazônia revela como a extração de recursos naturais opera dentro de um sistema mundial que demanda *commodities* enquanto externaliza os custos ambientais.

Atualmente, no Pará, esta dinâmica manifesta-se materialmente através dos ciclos históricos de exploração mapeados por Becker (2005): a borracha que deixou vestígios em redes de extração dispersas; a pecuária que impôs grandes polígonos de pastagem; a mineração que criou enclaves e corredores de infraestrutura; e o agronegócio contemporâneo que regulariza geometricamente a paisagem.

Tendo em vista isso, o mapeamento de corte raso realizado neste trabalho captura justamente a materialização espacial mais recente destes ciclos - especialmente a expansão pecuária e agropecuária -, documentando como padrões históricos de apropriação se atualizam em novas formas de desmatamento.

Isso posto, o padrão contemporâneo de corte raso para formação de pastagens não é, portanto, um acidente histórico, mas o resultado de políticas deliberadas de ocupação territorial e incentivos econômicos estruturantes.

Conforme demonstra Fearnside (2005) em análise seminal sobre as causas do desmatamento amazônico, estas políticas incluem: crédito rural subsidiado especificamente para abertura de novas áreas; regularização fundiária que beneficia quem desmata; isenções fiscais para projetos na fronteira agrícola; e investimentos em infraestrutura (rodovias, hidrelétricas) que valorizam terras desmatadas - conjunto de incentivos que, nas palavras do autor, transformam floresta em passivo e pasto em ativo.

Conforme a teoria da fronteira, desenvolvida por Turner (1893) e posteriormente adaptada para o contexto amazônico por autores como Schmink e Wood (1992), oferece um marco analítico crucial, onde, segundo esta perspectiva, a fronteira não é meramente uma linha geográfica, mas um espaço social dinâmico onde atores diversos

(garimpeiros, madeireiros, pecuaristas, agricultores familiares, povos indígenas) disputam recursos e direitos sob regimes de propriedade frequentemente ambíguos.

Além disso, a indefinição fundiária, que atinge cerca de 30% das terras no Pará segundo o INCRA (2023), cria um ambiente propício para a grilagem e o desmatamento especulativo, onde a ocupação física precede e legitima a reivindicação de propriedade (Alston et al., 2000).

Sendo assim, essa compreensão eco política é essencial para contextualizar os resultados do monitoramento por satélite e tentar traduzir a enorme base de dados geoespaciais gerados diariamente sobre o território amazônico, pois ainda que os métodos mais avançados produzam respostas mais rápidas, como alerta Scott (1998) em *"Seeing Like a State"*, tecnologias de medição e classificação incluindo o sensoriamento remoto são instrumentos através dos quais estados simplificam realidades complexas para governá-las.

Isso posto, os polígonos de desmatamento mapeados por satélites não são representações neutras, mas construções técnicas que tornam visíveis certas formas de transformação territorial enquanto ocultam outras (como a degradação florestal não total). Portanto, reconhecer esta dimensão política do monitoramento é fundamental para evitar o fetichismo tecnológico que atribui à inteligência artificial um poder salvacionista independente dos contextos sociais em que é aplicada.

2.1.4 O papel do sensoriamento remoto como tecnologia de vigilância ambiental

A transição do monitoramento visual para o algorítmico representa não apenas uma mudança técnica, mas uma mudança na forma de produzir conhecimento sobre a floresta, uma vez que o sensoriamento remoto opera por meio do que Latour (1987) descreve como cadeias de referência — séries de traduções que convertem a radiação eletromagnética em números, depois em pixels, em classes temáticas e, por fim, em subsídios para políticas públicas.

Ou seja, cada elo dessa cadeia envolve escolhas metodológicas que influenciam a interpretação dos dados e os resultados obtidos.

Em adição a isso, a teoria da assinatura espectral, desenvolvida a partir dos trabalhos pioneiros de Swain e Davis (1978) sobre abordagem quantitativa em sensoriamento remoto, postula que diferentes materiais na superfície terrestre refletem

a radiação eletromagnética de maneiras características, criando assinaturas identificáveis no espaço espectral multidimensional.

No contexto amazônico, contudo, esta teoria enfrenta desafios particulares documentados por Asner (2001): a alta biodiversidade gera variabilidade espectral intrínseca que sobrepõe assinaturas de diferentes tipos florestais, enquanto fenômenos atmosféricos persistentes (cobertura de nuvens que atinge até 80%, aerossóis de queimadas) e variações de iluminação (ângulo solar, topografia complexa) introduzem ruído sistemático que pode mimetizar falsamente sinais de desmatamento ou ocultar mudanças reais.

Sendo assim, a resposta a estes desafios tem evoluído através de diferentes paradigmas de classificação, como o paradigma paramétrico, dominante até os anos 1990 - e utilizado nas primeiras versões do sistema PRODES, o qual assumia distribuições estatísticas específicas (normalmente gaussianas) para as assinaturas espectrais de cada classe.

Conforme detalha Shimabukuro et al. (2014), pesquisador do INPE envolvido no desenvolvimento do programa, o classificador de máxima verossimilhança (*Maximum Likelihood*) exemplifica esta abordagem: baseado no teorema de Bayes, ele atribui cada pixel à classe com maior probabilidade dado seu vetor espectral, pressupondo distribuições normais multivariadas para cada classe.

Esta suposição, porém, constitui sua limitação fundamental na Amazônia: a complexa estrutura da floresta tropical - com múltiplos estratos vegetais, sombreamento diferencial, e alta diversidade específica - viola sistematicamente a pressuposição de normalidade, gerando erros de classificação que exigiam extensa pós-correção manual nas primeiras décadas do monitoramento por satélite.

De mesmo modo, o advento dos classificadores não-paramétricos - como as árvores de decisão (CART) e máquinas de vetores de suporte (SVM) - representou um avanço conceitual ao abandonar completamente suposições distribucionais prévias, permitindo modelar relações complexas nos dados espectrais. Porém, foi com os métodos de *ensemble learning* - particularmente o Random Forest - que se alcançou uma verdadeira síntese entre flexibilidade e robustez.

Como documentam Belgiu e Drăguț (2016) em revisão seminal sobre aplicações de RF em sensoriamento remoto, estes algoritmos não buscam modelar explicitamente distribuições espectrais, mas aprendem empiricamente as fronteiras de decisão que

melhor separam as classes no espaço de características através da construção de múltiplas árvores de decisão treinadas em subconjuntos aleatórios dos dados e variáveis, cujas predições são agregadas por votação majoritária - abordagem que combina a capacidade adaptativa das árvores individuais com a estabilidade estatística do *bagging*.

Outrossim, um avanço teórico crucial para o monitoramento amazônico foi a incorporação da dimensão temporal, a partir da teoria de séries temporais de imagens de satélite, desenvolvida por Zhu e Woodcock (2014) no algoritmo *Continuous Change Detection and Classification* (CCDC), reconhece que a detecção de mudanças é mais confiável quando considera não apenas um instante no tempo, mas a trajetória espectral completa de cada pixel ao longo de toda a série disponível.

Esta abordagem de análise de séries temporais tem sido amplamente aplicada e validada para a detecção de mudanças de cobertura da terra em ambientes tropicais, incluindo a Amazônia (Ponzoni et al., 2016; Lima et al., 2019).

2.1.5 O uso do algoritmo Random Forest na análise e na produção de informações geoespaciais

O Random Forest implementa uma estratégia epistemológica que ecoa o princípio da sabedoria das multidões (Surowiecki, 2004), onde múltiplas perspectivas imperfeitas, quando adequadamente combinadas, produzem conhecimento superior. Tecnicamente, esta abordagem se materializa através dos mecanismos de *ensemble learning* formalizados por Dietterich (2000) e implementados no algoritmo Random Forest por Breiman (2001).

A partir disso, a aleatorização dupla no conjunto de treinamento (*bagging*) e nas variáveis consideradas em cada divisão funciona como um mecanismo de regularização implícita que previne o sobreajuste. Teoricamente, como demonstra Breiman (2001), o erro de generalização do RF converge para um limite à medida que o número de árvores aumenta, sendo limitado por:

$$Erro \leq \frac{\bar{p}(1-s^2)}{s^2} \quad (1)$$

onde $\bar{p}$ é a correlação média entre árvores e s é a força de cada árvore individual.


Esta formulação matemática explica a robustez empírica do algoritmo: ao reduzir $\bar{\rho}$ através da aleatorização, reduz-se o erro total mesmo com árvores individuais relativamente fracas.

Ademais, bem como destacado por Lorenzetti e Telocken (2016), o algoritmo Random Forest (RF) emprega uma lógica de dividir para conquistar. Essa abordagem de *ensemble* confere ao método uma robustez superior à de uma única árvore de decisão, mitigando o risco de sobreajuste (*overfitting*) e demonstrando menor sensibilidade a ruídos presentes nos dados.

Operacionalmente, o RF gera um conjunto múltiplo de árvores de decisão, cada uma treinada a partir de amostras aleatórias do conjunto de dados original (X) e desenvolvendo regras de classificação independentes.

Para produzir uma predição final (Y), o algoritmo agrega os resultados individuais de todas as árvores por meio de um mecanismo de votação majoritária, selecionando como classe de saída aquela que receber o maior número de votos entre os classificadores base, conforme ilustrado na Figura 2.

Figura 2 - N-árvores para escolha da decisão final através de indicação (voto).



Fonte: Galvão (2023).

Sobretudo, contrariamente à crítica comum de que métodos de machine learning são caixas pretas (*black boxes*), o Random Forest oferece mecanismos interpretativos valiosos, já que sua métrica de importância de variáveis, calculada pela diminuição

média da impureza de Gini (*Mean Decrease in Impurity* - MDI), quantifica objetivamente a contribuição de cada preditor para a acurácia do modelo (Breiman, 2001).

Esta funcionalidade transcende a classificação pura, atuando como uma ferramenta de descoberta científica que identifica quais atributos espectrais são mais discriminativos para um determinado problema, assim destacado em revisões sobre interpretabilidade em sensoriamento remoto (Belgiu; Drăguț, 2016).

No contexto amazônico, esta capacidade analítica tem gerado insights valiosos e contraintuitivos, como a superioridade do NBR sobre o NDVI para detecção de corte raso, um achado que desafia pressupostos estabelecidos e foi empiricamente demonstrado para a região (Ponzoni et al., 2016).

Ademais, a aplicação do RF ao sensoriamento remoto também levanta questões filosóficas sobre a objetividade do conhecimento produzido, argumenta Daston e Galison (2007) em sua história da objetividade científica, cada época desenvolve tecnologias que materializam seus ideais epistêmicos.

O RF, com sua ênfase na aprendizagem a partir de dados sem modelos pré-concebidos, encarna um ideal de objetividade mecânica onde o julgamento humano é minimizado em favor de procedimentos algorítmicos.

Porém, essa suposta neutralidade é ilusória: as amostras de treinamento carregam os vieses de quem as coletou, as variáveis preditoras refletem escolhas teóricas sobre o que é relevante, e os hiperparâmetros (número de árvores, profundidade máxima) introduzem arbitrariedades que influenciam os resultados.

Dessa forma, embora o Random Forest seja frequentemente apresentado como um método objetivo e robusto, sua operação depende de decisões humanas que atravessam desde a coleta e rotulagem dos dados até a seleção de variáveis e o ajuste de parâmetros, o que relativiza a ideia de neutralidade algorítmica (STROBL et al., 2007; PROBST et al., 2019).

2.1.6 Síntese teórica: por uma abordagem interdisciplinar para o monitoramento amazônico.

A fundamentação aqui apresentada converge para uma proposição teórica central: o monitoramento efetivo do desmatamento na Amazônia requer uma abordagem interdisciplinar que integre três modos de conhecimento frequentemente

tratados como antagônicos.

Primeiro, o conhecimento situado das ciências sociais, que compreende os contextos históricos, políticos e culturais que produzem os padrões de desmatamento. Como demonstra a eco política, o corte raso no Pará é indissociável de conflitos fundiários e modelos de desenvolvimento que remontam à ditadura militar.

Segundo, o conhecimento biofísico das ciências naturais, que quantifica os processos ecológicos, climáticos e espectrais envolvidos na transformação da floresta, ou seja, a teoria da assinatura espectral e a análise de séries temporais fornecem as ferramentas para detectar e medir estas transformações.

Terceiro, o conhecimento algorítmico da ciência da computação, que desenvolve métodos para extrair padrões de grandes volumes de dados, isto é, o Random Forest exemplifica como técnicas sofisticadas de *machine learning* podem automatizar análises complexas com alta precisão.

Esta tríade epistemológica informa o desenho metodológico do presente trabalho, onde o modelo proposto não é apresentado como solução tecnocrática autossuficiente, mas como ferramenta situada dentro de um contexto socioecológico específico, cujos resultados devem ser interpretados à luz das teorias aqui discutidas. Portanto, a alta acurácia alcançada (98,37%) não é um fim em si mesma, mas um meio para produzir evidências mais confiáveis sobre um fenômeno que, no fim, é tão político quanto ecológico.

2.2 Justificativa

Visto isso, o presente trabalho apresenta uma importância para o desenvolvimento de ferramentas ágeis, acessíveis e com foco local para apoiar o monitoramento ambiental, pois ainda que, atualmente, sistemas como o PRODES (Projeto de Monitoramento do Desmatamento na Amazônia Legal por Satélite) ofereçam estatísticas importantes, esse atua em escopo nacional e frequência anual. Por isso, busca-se explorar um método mais acessível e voltado à realidade urgente de órgãos locais de fiscalização do Estado do Pará, baseada em dados públicos e técnicas de aprendizado de máquina, como o Random Forest.

Em síntese, o algoritmo se destaca como uma ferramenta eficaz para classificação de grandes volumes de dados provenientes do sensoriamento remoto.

Posto que, por apresentar elevada precisão e robustez frente à variabilidade espectral da vegetação tropical e disponibilidade em bibliotecas de código aberto, esse método permite respostas precisas e replicáveis, tornando-o particularmente adequado para operações de monitoramento e fiscalização ambiental (Vieira *et al.*, 2022; Silva, 2023).

Porquanto, o destaque de mapas ilustrativos da área de estudo Figura 3 e 4 constituem um elemento fundamental desse trabalho, em virtude de viabilizar a representação espacial dos padrões de desmatamento e a visualização das regiões mais impactadas, tanto no nível estadual quanto na esfera municipal.


Imediatamente, essas cartas contribuem para a compreensão dos fenômenos ambientais e para a clareza na comunicação, a fim de reforçar o caráter aplicado do estudo (Beckmam *et al.*, 2024). Imediatamente, é possível perceber o Pará com mais de 54 mil km² desmatados desde 2008 até 2024, já o município mais afetado pelo fenômeno representa quase 7 mil km² desmatados desde 2008.

Figura 3 - Mapa estadual de incrementos de desmatamento na Amazônia de 2008 até 2024.



Fonte: INPE (2024), adaptado de TerraBrasilis.

Figura 4 - Mapa municipal de incrementos de desmatamento na Amazônia de 2008 até 2024.



Fonte: INPE (2024), adaptado de TerraBrasilis.

Certamente, a realização desse estudo se destaca não apenas pelo interesse acadêmico, mas também pela relevância prática, haja vista que o método proposto pode ser incorporado a sistemas de monitoramento operacionais e visa oferecer subsídios diretos às ações de fiscalização estadual.

Desse modo, em frente à elevada taxa de desmatamento no Estado do Pará, a aplicação de técnicas de inteligência artificial aliadas ao sensoriamento remoto mostram-se capazes de apoiar não só políticas públicas, mas também, o planejamento territorial e a conservação ambiental de maneira ágil e eficaz (INPE, 2022; Silva, 2023).

3 OBJETIVOS

Para alcançar a finalidade proposta neste trabalho, os objetivos foram organizados em um objetivo geral, que direciona a abordagem central, e objetivos específicos, os quais detalham as etapas necessárias para sua consecução.

O objetivo geral sintetiza a ambição científica e aplicada do estudo, enquanto os específicos desdobram-se em ações metodológicas, analíticas e críticas que garantem tanto o rigor técnico quanto a reflexão epistemológica e prática demandada pela temática.

3.1 Geral

Desenvolver e validar um modelo de classificação de imagens de satélite baseado no algoritmo Random Forest para identificação de áreas de corte raso no estado do Pará.

3.2 Específicos

- Treinar o modelo de classificação com o Random Forest;
- Avaliar o desempenho por métricas estatísticas;
- Aplicar o modelo treinado a uma área nunca vista pelo dispositivo;
- Analisar ambientalmente a classificação da área desconhecida classificada pelo modelo;
- Discutir limites técnicos, éticos e metodológicos;


Documentar todo o *pipeline* metodológico *online*.

4 METODOLOGIA DA PESQUISA

A pesquisa é do tipo aplicada, com abordagem quantitativa, tendo como objetivo o monitoramento do desmatamento por corte raso no Estado do Pará através de imagens de satélite e técnicas de inteligência artificial.

Logo, pode-se observar na Figura 5, um fluxograma representado as etapas metodológicas até alcançar os resultados.

Figura 5 - Fluxograma metodológico.



Fonte: A Autora (2024).

O processamento computacional utilizado neste estudo foi implementado em linguagem Python, incluindo etapas de treinamento do classificador Random Forest, cálculo dos índices espectrais NDVI, NDMI e NBR e classificação da imagem Landsat. O *script* utilizado no processo encontra-se apresentado no Apêndice B.

4.1 Aquisição das imagens

A coleta de dados para o monitoramento do desmatamento por corte raso no Estado do Pará foi realizada a partir de imagens do satélite Landsat 8, obtidas através da plataforma Google Earth Engine (GEE) *code editor*, sendo assim o *script* (Apêndice C) usado para atender toda a metodologia apresentada está disponível no github: <https://github.com/nadelly/O-uso-de-intelig-ncia-artificial-para-classifica-o-d-eimagens-de-sat-lite-no-estado-do-Par-..git>.

Logo, a área de amostragem foi definida a partir de coordenadas representativas da região de estudo, com o auxílio de polígonos de desmatamento consolidados pelo INPE, além disso, para garantir a qualidade das imagens, foram aplicados filtros temporais: apenas imagens adquiridas em 2024 foram consideradas para análise.

Em seguida, visando minimizar a contaminação atmosférica nas assinaturas espectrais, adotou-se um rigoroso critério de qualidade, selecionando apenas cenas com cobertura de nuvens inferior a 10%. Este limiar é consistente com as práticas de pré-processamento estabelecidas para a geração de produtos de reflectância de superfície (Zhu & Woodcock, 2012; Roy et al., 2010)

Outrossim, a fim de garantir a qualidade dos dados, ainda no ambiente GEE, gerou-se uma visualização RGB, através das bandas SR_B4 (vermelho), SR_B3 (verde) e SR_B2 (azul), assim como, utilizou-se o produto de reflectância de superfície (*Surface Reflectance*) do Landsat Collection 2, já previamente corrigido atmosféricamente.

Por conseguinte, para análise quantitativa, foram exportadas as bandas SR_B4 a SR_B7 em formato *raster*, na resolução espacial de 30 metros, as quais consideram informações ópticas do sensor *Operational Land Imager* (OLI) nas bandas 4 (vermelho, 0,64 0,67 μm), 5 (infravermelho próximo, 0,85 0,88 μm), 6 (infravermelho de ondas curtas SWIR 1, 1,57 1,65 μm) e 7 (infravermelho de ondas curtas SWIR2, 2,11 2,29 μm).

Tendo em vista isso, as bandas selecionadas são adequadas para detectar o desmatamento (Tabela 1), pois a banda 4 é sensível à clorofila e permite diferenciar vegetação saudável de áreas desmatadas, sendo utilizada em índices de normalização (Lima et al., 2019).

Bem como, a banda 5 no infravermelho próximo, identifica vigor da vegetação e áreas desmatadas, ademais as bandas 6 e 7 (SWIR 1 e SWIR 2) são sensíveis ao conteúdo de umidade do solo e da vegetação e servem para distinguir áreas alteradas pelo desmatamento (USGS, 2020).

Tabela 1 - Bandas escolhidas.

Sensor	Banda	Faixa espectral	Sensibilidade	Importância
OLI	4	Vermelho (0,64–0,67 μm)	Sensível à clorofila	Alta - essencial para distinguir vegetação de área desmatada
OLI	5	Infravermelho próximo (0,85–0,88 μm)	Alta refletância em vegetação saudável; indica biomassa	Alta – essencial para detectar vegetação densa de solo exposto
OLI	6	SWIR1 (1,57–1,65 μm)	Sensível à umidade do solo e vegetação	Média – útil para refinar áreas com solo úmido ou vegetação residual
OLI	7	SWIR2 (2,11–2,29 μm)	Sensível à vegetação seca e detritos vegetais	Média – ajuda a identificar resíduos vegetais ou degradação após corte raso

Fonte: A Autora (2025).

4.1.1 Características dos dados e escala de reflectância

As imagens utilizadas neste trabalho são do produto USGS Landsat 8 *Level 2, Collection 2, Tier 1*, acessado via Google Earth Engine (GEE) sob o código LANDSAT/LC08/C02/T1_L2 (Google, 2026). Este produto fornece dados de reflectância de superfície (*surface reflectance*), que representam a fração da luz solar refletida pelo alvo após correções atmosféricas, sendo o padrão para análises quantitativas de mudança de cobertura do solo, sendo uma característica operacional deste conjunto de dados e seu armazenamento em formato inteiro escalado.

Para eficiência computacional e de armazenamento, os valores físicos de reflectância (que variam teoricamente de 0 a 1) são convertidos e distribuídos como números inteiros (*Digital Number - DN*), numa faixa de 0 a 65.535.

Conforme documentado pelo provedor do dado, para recuperar o valor físico da refletância (ρ) a partir do DN extraído, aplica-se a seguinte transformação linear padrão para todas as bandas ópticas (SR_B1 a SR_B7):

$$\rho = \text{DN} \times 0,0000275 - 0,2 \quad (2)$$

Na equação (2), 0,0000275 é o fator de escala (*scale*) e -0,2 é o deslocamento (*offset*). Portanto, os valores presentes nas colunas Landsat8_2024-07-23_1 a Landsat8_2024-07-23_7 do *dataset* de treinamento (Apêndice A) correspondem aos valores inteiros DN, e não aos valores de refletância pura.

Esta convenção não prejudica a análise, pois a conversão para refletância é determinística e os cálculos dos índices espectrais, baseados em razões normalizadas, são matematicamente invariantes a esta transformação linear, assegurando a consistência dos resultados.

4.2 Coleta de amostras

A definição das amostras ocorreu no ambiente QGIS, através de uma imagem do município de Senador José Porfírio, datada em 23/07/2024 do satélite Landsat 8 de nível 2, reconhecidas por sua abrangência espectral, confiabilidade e disponibilidade histórica para monitoramento ambiental, juntamente com as áreas de desmatamento detectadas pelo DETER, que forneceram dados oficiais sobre o corte raso na região de estudo.

Com base nessas informações, foram criados polígonos vetoriais que representam as classes de interesse: classe 0, referente à vegetação e classe 1, correspondente à supressão. Esta metodologia seguiu procedimentos consolidados para análise de mudanças na cobertura do solo, o que garantiu precisão na caracterização das áreas amostradas ao permitir comparações consistentes com estudos anteriores (Pereira et al., 2016).


Após a definição dos polígonos, foram gerados pontos aleatórios dentro de cada área, de maneira que assegurasse uma amostragem representativa e minimizasse vieses relacionados à distribuição espacial dos dados, como visto na Figura 6. Logo, cada ponto foi associado aos valores dos pixels da imagem *raster* (matriz) por meio do

plugin *Point Sampling Tool* no QGIS.

Este *plugin* possibilitou extrair os valores DN de cada banda, transformando a informação contida no formato matricial da imagem em dados quantitativos que puderam ser analisados estatisticamente.

O processo garantiu que cada ponto amostral contivesse informações completas sobre as características espectrais da superfície terrestre em virtude de viabilizar análises detalhadas sobre a cobertura do solo.

Figura 6 - Mapa da região amostral.



Fonte: A Autora (2025).

Com os pontos amostrados e os valores das bandas espectrais obtidos, criou-se um arquivo CSV com as classes de referência e os valores correspondentes de cada banda como visto no APÊNDICE A - *Dataset*.

Este arquivo serviu como base para o cálculo de índices espectrais amplamente utilizados em estudos de monitoramento ambiental, como o NBR (índice de Queimada Normalizado), o NDVI (Índice de Vegetação por Diferença Normalizada) e o NDMI (Índice de Umidade por Diferença Normalizada).

Porquanto, o NBR é um índice espectral amplamente utilizado no sensoriamento remoto para detectar e mapear áreas queimadas, calculando a diferença normalizada entre a refletância nas faixas do infravermelho próximo e infravermelho de ondas curtas antes e depois de um incêndio, sendo fundamental para analisar a severidade do fogo.

Estudos aplicados no contexto brasileiro mostram que o NBR apresenta maior capacidade de discriminar áreas queimadas de outros tipos de cobertura, justificando sua aplicação no monitoramento e quantificação de queimadas em ecossistemas brasileiros (Strobl et al., 2007).

Por conseguinte, o NDVI permite avaliar o vigor e a densidade da vegetação ao identificar áreas com cobertura vegetal saudável ou em processo de degradação, enquanto o NDMI fornece informações sobre o conteúdo de água na vegetação e no solo, além de contribuir para a detecção de estresse hídrico ou alterações ambientais decorrentes de desmatamento (Braga, 2018; Silva et al., 2021).

Dessa maneira, a combinação de métodos de amostragem espacial, extração de valores espectrais e cálculo de índices garantiu resultados robustos e consistentes, os quais possibilitaram análises precisas da dinâmica espacial e temporal das áreas estudadas, além de oferecer subsídios científicos para a manutenção de políticas de conservação e manejo ambiental.

$$NBR = (NIR - SWIR2) / (NIR + SWIR2) \quad (3)$$

$$NDVI = (NIR - Red) / (NIR + Red) \quad (4)$$

$$NDMI = (NIR - SWIR1) / (NIR + SWIR1) \quad (5)$$

4.3 Treinamento e avaliação do modelo

O treinamento do modelo foi realizado com o algoritmo Random Forest, pertencente à família dos métodos de *ensemble learning*, essa abordagem combina múltiplos modelos de decisão individuais para produzir um resultado mais robusto e confiável.

No caso específico do RF, múltiplas árvores de decisão são construídas a partir de subconjuntos aleatórios dos dados e das variáveis preditoras. Cada árvore gera uma classificação, e a decisão final é tomada por meio do voto da maioria, reduzindo a

chance de erros individuais (Breiman, 2001).

4.3.1 Configuração dos hiperparâmetros do algoritmo Random Forest

A configuração dos hiperparâmetros do Random Forest foi estabelecida com base na literatura especializada (Breiman, 2001; Belgiu & Drăguț, 2016) e visa otimizar o equilíbrio entre capacidade preditiva e eficiência computacional para o problema específico de classificação de corte raso. A Tabela 2 resume os principais hiperparâmetros configurados.

Tabela 2 - Hiperparâmetros do Random Forest configurados.

Hiperparâmetro	Valor	Justificativa
<i>n_estimators</i>	100	Estabilidade estatística vs custo computacional
<i>max_features</i>	'sqrt'	Reduz correlação entre árvores
<i>criterion</i>	'gini'	Eficiente para classificação binária
<i>random_state</i>	42	Reprodutibilidade
<i>max_depth</i>	<i>none</i>	Evita poda prematura

Fonte: A Autora (2025).

A configuração *n_estimators*=100 fundamenta-se na convergência do erro demonstrada por Breiman (2001) e validada em revisões da área (Belgiu; Drăguț, 2016; Ball et al., 2022). A robustez do algoritmo a variações paramétricas, que permite essa escolha sem *tuning* extensivo, é corroborada por análises sistemáticas (Probst et al., 2019). Para o contexto específico do sensoriamento remoto amazônico, estudos regionais indicam a eficácia de configurações similares (Ponzoni et al., 2016).

A adoção do critério de Gini (*criterion*='gini') para divisão dos nós segue recomendações para problemas de classificação binária, sendo computacionalmente eficiente sem comprometer acurácia quando comparado à entropia (Hastie et al., 2009).

No contexto deste trabalho, com duas classes com boa separabilidade espectral (vegetação vs. corte raso), o índice de Gini oferece vantagens práticas de implementação.

O mecanismo de aleatorização *max_features='sqrt'*, onde cada divisão considera aproximadamente $\sqrt{10} \approx 3$ variáveis, é central para a filosofia do *ensemble*. Conforme estabelecido por Breiman (2001), esta redução sistemática da correlação entre árvores (ρ na formulação teórica) aumenta a diversidade do modelo, sendo particularmente eficaz para dados espectrais inerentemente correlacionados (Ball et al., 2022).

A configuração *max_depth=None* combinada com *min_samples_split=2* permite crescimento arbóreo completo, transferindo o controle de complexidade para os mecanismos intrínsecos de regularização do Random Forest: *bagging (bootstrap=True)* e seleção aleatória de variáveis. Esta abordagem, validada por Probst et al. (2019) em análise de sensibilidade hiperparamétrica, prioriza a captura de relações não-lineares complexas, adequadas à heterogeneidade florestal amazônica.

A fixação da semente aleatória (*random_state=42*) assegura reprodutibilidade total, requisito fundamental para pesquisa científica e validação interpares. Os demais hiperparâmetros mantiveram valores padrão da implementação *Scikit-learn*, decisão justificada pela robustez documentada do algoritmo a configurações não-otimizadas (Probst et al., 2019).

Em síntese, esta configuração não resultou de *tuning* automatizado, mas de escolhas fundamentadas que equilibram sofisticação técnica e praticidade operacional. A validação cruzada subsequente (seção 5.1) e o desempenho excepcional em dados independentes confirmam sua adequação ao problema específico de detecção de corte raso no Pará.

4.3.2 Avaliação do modelo

Para avaliar o desempenho do modelo, os dados de amostras coletadas (410 amostras totais) foram divididos em dois grupos: 70% (287 amostras) destinados ao treinamento e 30% (127 amostras) para os testes. Essa proporção é amplamente adotada em estudos de aprendizado de máquina, pois garante um equilíbrio entre quantidade de dados suficiente para treinar o modelo e dados independentes para testar sua capacidade de generalização (Kuhn & Johnson, 2013).

Visando garantir a robustez estatística da avaliação, foi implementada uma validação cruzada com 10 *folds* (10-fold cross-validation) durante a fase de treinamento, nessa técnica, o conjunto de treinamento é subdividido em 10 partes (*folds*) de tamanho aproximadamente igual. O modelo é treinado 10 vezes, utilizando cada vez 9 *folds* para treino e 1 *fold* para validação, rodando de forma que cada *fold* sirva uma vez como conjunto de validação.

Este procedimento permite obter uma estimativa mais confiável do desempenho do modelo, reduzindo a variabilidade associada a uma única divisão treino teste e fornecendo uma medida da consistência interna do classificador (Reyaeilzadeh et al., 2009).

Além da divisão entre conjuntos de treinamento e teste, foram adotados procedimentos metodológicos para reduzir o risco de sobreajuste (*overfitting*) e garantir a capacidade de generalização do modelo. A utilização da validação cruzada com 10 *folds* permite avaliar o desempenho do algoritmo em diferentes partições do conjunto de dados, reduzindo a dependência de uma única divisão treino-teste.

Adicionalmente, o desempenho final foi avaliado utilizando um conjunto de teste independente, composto por amostras que não participaram do processo de treinamento. Esse procedimento permite verificar se o modelo é capaz de reconhecer padrões espectrais em dados não observados anteriormente, evitando que o classificador apenas memorize as amostras utilizadas no treinamento.

A consistência entre os resultados obtidos na validação cruzada e no conjunto de teste indica que o modelo apresenta boa capacidade de generalização, reduzindo a probabilidade de extrapolações indevidas e garantindo maior confiabilidade na aplicação para detecção de corte raso em imagens de satélite.

Ademais, a validação do desempenho nos dados reservados para teste, foi realizada por meio das métricas fornecidas pela função *classification_report* da biblioteca *Scikit-learn*: acurácia, precisão, sensibilidade (*recall*) e F1-score. Isto é, essas métricas permitiram avaliar a capacidade do modelo em classificar corretamente áreas de desmatamento por corte raso de áreas vegetadas.

Sendo assim, a acurácia fornece uma visão geral do desempenho do modelo, enquanto a precisão e o *recall* oferecem *insights* sobre a capacidade do modelo em identificar corretamente as classes de interesse. O F1-score, sendo a média harmônica entre precisão e *recall*, oferece uma medida equilibrada do desempenho do modelo,

especialmente em cenários com classes desbalanceadas (Sasaki, 2007).

Para uma análise detalhada dos erros de classificação nos dados de teste, foi gerada uma matriz de confusão. Esta matriz tabula as classificações corretas e incorretas para cada classe, permitindo calcular métricas derivadas como especificidade (capacidade de identificar corretamente instâncias negativas) e análise dos tipos de erro: falsos positivos (áreas classificadas como corte raso que na verdade são vegetação) e falsos negativos (áreas de corte raso classificadas erroneamente como vegetação).

A matriz de confusão oferece uma visão granular do comportamento do modelo, complementando as métricas globais de desempenho (Powers, 2011). Além disso, uma das vantagens do algoritmo Random Forest é sua capacidade de quantificar a importância relativa das variáveis preditoras.

Esta análise foi realizada utilizando o método baseado na diminuição da impureza de Gini (*Gini impurity decrease*), que mede quanto cada variável contribui para reduzir a impureza nas divisões das árvores de decisão que compõem a floresta.

Variáveis com maior importância são aquelas que consistentemente produzem divisões mais puras, separando efetivamente as classes de interesse. Esta análise não apenas valida a seleção de variáveis realizada, mas também oferece insights sobre quais atributos espectrais são mais discriminativos para detecção de corte raso no contexto amazônico, elucidando a lógica espectral aprendida pelo modelo.

A implementação do código em Python (disponível no github: <https://github.com/nadelly/O-uso-de-inteligencia-artificial-para-classificar-o-d-e-imagens-de-sat-lite-no-estado-do-Par-..git>) seguiu as etapas descritas na Figura 5, utilizando a biblioteca *Scikit-learn* para o treinamento e avaliação do algoritmo Random Forest, e a biblioteca *Rasterio* para a classificação da imagem com base no modelo treinado.

Sendo assim, a implementação do modelo foi realizada em linguagem Python, utilizando principalmente a biblioteca *Scikit-learn* para treinamento e avaliação do algoritmo Random Forest, além da biblioteca *Rasterio* para aplicação do modelo sobre imagens *raster*. O código completo utilizado no desenvolvimento do modelo encontra-se disponível no repositório público do projeto.

O trecho abaixo exemplifica a etapa de treinamento do modelo Random Forest:

```

from sklearn.ensemble import RandomForestClassifier

rf = RandomForestClassifier(
    n_estimators=100,
    max_features='sqrt',
    criterion='gini',
    random_state=42
)

rf.fit(X_train, y_train)

```

Esse procedimento treina o modelo a partir das amostras espectrais extraídas das imagens Landsat, permitindo que o algoritmo aprenda os padrões associados às classes vegetação e corte raso.

Além das métricas tradicionais de classificação, a avaliação de classificações em sensoriamento remoto também considera os chamados erros de omissão e erros de comissão, amplamente utilizados na literatura para análise da qualidade temática de mapas derivados de imagens de satélite (Congalton; Green, 2009).

O erro de comissão ocorre quando uma área é classificada pelo modelo como pertencente a determinada classe, embora na realidade pertença a outra. No contexto deste estudo, esse erro corresponde aos casos em que áreas de vegetação são classificadas como corte raso, configurando falsos positivos.

Por outro lado, o erro de omissão ocorre quando uma área que pertence a uma determinada classe não é identificada corretamente pelo modelo. No caso da detecção de desmatamento, esse erro ocorre quando áreas de corte raso são classificadas como vegetação, caracterizando falsos negativos.

A análise desses erros é fundamental para compreender as limitações do modelo, uma vez que cada tipo de erro possui implicações distintas para aplicações de monitoramento ambiental. Em operações de fiscalização, por exemplo, erros de comissão podem levar à verificação de áreas que não apresentam desmatamento, enquanto erros de omissão podem resultar na não detecção de áreas efetivamente desmatadas.

5 RESULTADOS E DISCUSSÕES

Este capítulo apresenta e discute os resultados obtidos com a implementação do modelo Random Forest para classificação de corte raso no estado do Pará. A análise está organizada em quatro partes principais:

1. Avaliação do desempenho preditivo do modelo por meio de métricas de classificação e validação cruzada;
2. Investigação da importância das variáveis espectrais na decisão do classificador;
3. Mapeamento temático e interpretação espacial dos padrões de desmatamento identificados na área de estudo;
4. Reflexão crítica sobre as limitações técnicas e metodológicas inerentes à abordagem adotada.

Os resultados são discutidos à luz do referencial teórico apresentado, buscando articular as evidências quantitativas com as dimensões políticas, ecológicas e metodológicas do monitoramento por sensoriamento remoto.

5.1 Análise do desempenho do modelo

O modelo desenvolvido demonstrou desempenho excepcional na classificação binária entre vegetação preservada e áreas de corte raso, no total foram 410 amostras coletadas, as quais foram divididas em duas partes: 287 amostras para treinamento e 123 amostras para teste.

Logo, a distribuição das amostras entre as classes de interesse e os conjuntos de treinamento e teste é apresentada na Tabela 3. Observa-se que, embora a classe vegetação seja mais representada, o balanceamento entre as classes no conjunto de teste permitiu uma avaliação robusta do modelo.

Tabela 3 - Distribuição das amostras por classe e conjunto de dados.

Categoria	Total	Treino (70%)	Teste (30%)
Vegetação	267	187	80
Corte Raso	143	100	43
Total	410	287	123


Fonte: A Autora (2025).

Inicialmente, os dados foram divididos em conjuntos de treinamento (70%) e teste (30%), sendo o conjunto de teste reservado exclusivamente para a avaliação final do modelo. A validação cruzada 10-*fold* foi aplicada com caráter complementar, com o objetivo de verificar a estabilidade do algoritmo frente a diferentes partições dos dados, não interferindo no processo de treinamento nem na geração do modelo final.

Portanto, a validação cruzada de 10 *folds* (Figura 7) reforçou a robustez estatística do modelo, apresentando uma acurácia média de 99,30% com desvio padrão de apenas 1,40% entre os *folds*, isso confirma que o desempenho do classificador é consistente e reproduzível, independentemente da partição dos dados utilizada.

Esses resultados indicam ausência de sobreajuste (*overfitting*) e alta capacidade de generalização, alinhando-se com boas práticas de avaliação de modelos de aprendizado de máquina (Kuhn & Johnson, 2013).

Figura 7 - Validação cruzada



Fonte: A Autora (2025).

Por conseguinte, as métricas de desempenho, calculadas sobre o conjunto de teste independente (30% dos dados), confirmam a robustez e confiabilidade do classificador, como visto na tabela 4.

Tabela 4 - Desempenho do modelo Random Forest nos dados de teste.

Métrica	Classe 0 (vegetação)	Classe 1 (corte raso)	Global
Precisão	98,75%	97,67%	98,21%
Recall	98,75%	97,67%	98,21%
F1-score	98,75%	97,67%	98,21%
Acurácia			98,37%
Suporte	80 amostras	43 amostras	123 amostras

Fonte: A Autora (2025).

A classificação realizada demonstrou desempenho excepcional, alcançando uma acurácia global de 98,37% na identificação de áreas de corte raso, esse resultado indica que 98,37% das amostras foram corretamente classificadas pelo modelo, superando a maioria dos valores reportados na literatura para regiões tropicais e ambientes ambientalmente heterogêneos.

Estudos que aplicam algoritmos de aprendizado de máquina, como o Random Forest, em classificações de uso e cobertura da terra normalmente reportam acurácias globais situadas entre aproximadamente 85% e 95%, como observado em trabalhos que obtiveram valores em torno de 91,7% e 89,98% utilizando imagens orbitais e técnicas semelhantes às adotadas neste estudo (Silva et al., 2021; Souza, 2022).

A elevada acurácia observada pode ser atribuída ao uso de produtos Landsat de nível 2, que fornecem valores DN após correções radiométricas e atmosféricas, à assinatura espectral bem definida da classe de corte raso, especialmente nas bandas do infravermelho próximo e de ondas curtas, e à aplicação do algoritmo Random Forest, reconhecido por seu elevado desempenho em problemas de classificação com dados não lineares.

Ainda assim, ressalta-se que valores elevados de acurácia devem ser interpretados à luz do contexto metodológico e da área de estudo, não implicando generalização automática dos resultados para outras regiões ou períodos.

Para a classe corte raso, a precisão atingiu 97,67%, indicando que, das áreas classificadas como desmatamento, 97,67% correspondem efetivamente a essa condição, com apenas 2,33% de falsos positivos. Embora não seja eliminação completa, essa baixa taxa é fundamental para ações de fiscalização, pois minimiza o desperdício de recursos em verificações de campo desnecessárias.

O *recall* para a classe corte raso foi de 97,67%, indicando que o modelo identificou corretamente a grande maioria das áreas efetivamente desmatadas. A

pequena taxa de falsos negativos (2,33%) poderia ser complementada por outras ferramentas de monitoramento em cenários operacionais. Para a vegetação, o *recall* de 98,75% assegura alta detecção de áreas preservadas, enquanto a precisão equivalente (98,75%) confirma a confiabilidade das classificações positivas para essa classe.


5.2 Análise da importância das variáveis

Em adição, a análise da importância relativa das variáveis preditoras, ilustrada na Figura 8 e detalhada na Tabela 5, oferece insights cruciais sobre os fatores espectrais que mais contribuíram para a classificação do modelo Random Forest. Calculada pela diminuição média da impureza de Gini (*Mean Decrease in Impurity* MDI), a importância revela que os índices NBR (*Normalized Burn Ratio*, 28,25%) e NDMI (*Normalized Difference Moisture Index*, 21,92%) foram os mais discriminativos, respondendo conjuntamente 50% da decisão do modelo.

Em contrapartida, o NDVI (*Normalized Difference Vegetation Index*), tradicionalmente utilizado para monitoramento de vegetação, apresentou a relevância de (6,06%) nesta aplicação específica. Esse padrão sugere que, na região estudada, o desmatamento por corte raso está intimamente associado a processos de queimada (captados pelo NBR) e à rápida redução de umidade superficial (detectada pelo NDMI), enquanto alterações no vigor vegetal (NDVI) são menos pronunciadas no período imediatamente após a supressão florestal.

Tais achados têm implicações diretas para o desenho de sistemas de alerta precoce, indicando que a combinação de índices sensíveis a fogo e umidade pode ser mais eficaz para a detecção oportuna de desmatamento na Amazônia.

Figura 8 - Importância relativa das variáveis no modelo Random Forest.



Fonte: A Autora (2025).

Tabela 5 - Ranking de importância das variáveis.

Posição	Variável	Importância Relativa	Interpretação
1	NBR	28,25%	Índice mais importante, relacionado a queimadas e alterações por fogo
2	NDMI	21,92%	Indicador de umidade do solo e vegetação
3	Banda 4 (Red - 0.64-0.67 µm)	17,21%	Sensível à clorofila, diferencia vegetação saudável
4	Banda 7 (SWIR2 - 2.11-2.29 µm)	14,91%	Sensível ao conteúdo de água em vegetação e solo
5	NDVI	6,06%	Menor importância nesta aplicação específica

Fonte: A Autora (2025).

Essa predominância do NBR indica que o desmatamento na área estudada está intrinsecamente associado a dois processos biofísicos principais: as queimadas e a rápida perda de umidade do solo e da vegetação, tendo em vista que esse índice é sensível a alterações pós-fogo e, revela que esse elemento é um componente quase

obrigatório do corte raso local não apenas como técnica de limpeza, mas como marcador espectral que persiste mesmo após a queima.

Já o NDMI atua como um termômetro da seca, capturando a drástica redução da umidade superficial que segue a remoção da cobertura florestal. Essas respostas espectrais corroboram que a floresta amazônica funciona como um sistema hidrológico integrado, e sua conversão para outros usos rompe esse ciclo, algo que o índice captura de forma aguda.

Dito isso, esses achados têm implicações práticas importantes para o monitoramento ambiental, pois sugerem que sistemas de alerta precoce na região poderiam focar no rastreamento de queimadas e na detecção de perda de umidade, em vez de depender apenas do declínio do verde aparente no espectro visível ao olho humano.

Além disso, reforçam a necessidade de abordagens específicas para cada bioma: o que funciona no Cerrado ou na Mata Atlântica pode não ser o ideal para a Amazônia. A escolha desses índices pelo modelo reflete uma lógica espectral local: aqui, o desmatamento se anuncia mais pelas cinzas e pela seca do que pela simples ausência de folhas.

5.3 Análise da matriz de confusão

A matriz de confusão (Figura 9), ferramenta padrão para avaliação de classificadores (Powers, 2011), detalha o desempenho do modelo, evidenciando acurácia global de 98,37% a partir de 121 classificações corretas em 123 amostras. Ambos as classes apresentam padrão simétrico, com apenas um falso positivo e um falso negativo cada, resultando na igualdade observada entre precisão e recall (vegetação: 98,75%; corte raso: 97,67%).

Figura 9 - Matriz de confusão

Avaliação do Desempenho da Classificação Binária		
Total de Amostras: 123		
	Vegetação Prevista	Corte Raso Prevista
Vegetação Real	79	1
Corte Raso Real	1	42

Verdadeiros positivos:

- Vegetação: 79
- Corte Raso: 42

Falsos positivos:

- Falsos Positivos: 1
- Falsos Negativos: 1

Fonte: A Autora (2025).

As taxas residuais de erro 1,25% de omissão para vegetação e 2,33% para corte raso situam-se dentro de parâmetros considerados operacionalmente aceitáveis para sistemas de alerta de desmatamento (Alencar et al., 2020). Em escala prática, isto significaria que, ao monitorar 100 km², aproximadamente 2,33 km² de desmatamento poderiam não ser detectados automaticamente. Em contextos de fiscalização ambiental, tal margem de falsos negativos é preferível a altas taxas de falsos positivos, que gerariam custos operacionais desnecessários (INPE, 2022).

A performance balanceada mitiga o viés classificatório comum em problemas com classes desbalanceadas (Sasaki, 2007), garantindo que o modelo não tende sistematicamente a superestimar ou subestimar nenhuma classe. Este equilíbrio simplifica a interpretação dos resultados e facilita a tomada de decisão, uma vez que os níveis de confiança são equivalentes para ambas as categorias.

Comparado a estudos similares na Amazônia, que reportam acurácias entre 85% e 95% para classificação binária de uso do solo (Silva et al., 2021; Souza, 2022), o desempenho alcançado (98,37%) posiciona-se na fronteira do estado da arte. Este resultado atribui-se à combinação adequada de variáveis preditoras com destaque para índices espectrais como NBR, NDMI e NDVI e à qualidade do conjunto de dados de treinamento.

5.4 Mapeamento e análise espacial


Após o treinamento, a implementação do modelo iniciou-se com a escolha de uma imagem Landsat-8 pelo Google Earth Engine através da plataforma *code editor*, com menos de 20% de cobertura de nuvens, datada de 30 de julho de 2024 (resolução espacial: 30 metros, área total: 99,50 km², município de Altamira-PA), essa informação matricial foi apontada para o modelo a partir de seu caminho no diretório da máquina para ser classificada.

Por conseguinte, em saída imediata, foi gerado um arquivo *raster* no formato GeoTIFF contendo a classificação binária para cada pixel, seguido pela Figura 10 em png, a qual materializa espacialmente a classificação obtida e apresenta em verde as áreas classificadas como vegetação preservada (58,39 km²) e em marrom as áreas de corte raso (41,11 km²).

Sendo assim, é possível observar que a distribuição espacial do desmatamento não é aleatória, uma vez que a concentração marcante no setor noroeste da área de estudo, onde os polígonos de corte raso exibem formas geométricas regulares e contornos retilíneos, padrão típico de conversão para uso agropecuário em grande escala.

Em contraste, as áreas de vegetação preservada aparecem principalmente no Sudeste, formando manchas florestais contínuas, porém já fragmentadas pelo avanço da fronteira agrícola, por isso esse produto não é meramente ilustrativo, mas um artefato cartográfico gerado através de um processo reprodutível que integra múltiplos ambientes tecnológicos.

Figura 10 - Mapa de classificação de corte raso.



Fonte: A Autora (2025).


Tendo em vista os pressupostos, para validação técnica da classificação gerada pelo modelo, o arquivo *raster* foi então importado para o QGIS 3.44, onde passou por um processo de vetorização que converteu pixels classificados como corte raso em polígonos vetoriais formato adequado para cálculos de área e análises espaciais avançadas.

Paralelamente, processou-se no QGIS, a imagem Landsat original para criar um mosaico com a composição colorida RGB (bandas 4,3,2 em falso colorido) para que não só, fornecesse contexto visual da paisagem (Figura 10), mas também, permitisse confrontar diretamente a classificação do modelo com a assinatura espectral real da

área: os polígonos vermelhos coincidem consistentemente com áreas de solo exposto, vegetação esparsa ou cicatrizes de queimada visíveis na composição colorida.

Além disso, a sobreposição também revela como o desmatamento se organiza espacialmente, frequentemente margeando estradas e avançando a partir de bordas já abertas, padrão típico de expansão da fronteira agropecuária na região.

Figura 11 - Mosaico de classificação de corte raso.



Fonte: A Autora (2025).

A vetorização dos resultados permitiu a visualização precisa das áreas classificadas:

Tabela 6 - Áreas classificadas na região de estudo.

Categoria	Área (km ²)	Porcentagem	Pixels
Vegetação	53,93	58,69%	63.251
Corte Raso	42,57	41,31%	47.305
Total	99,5	100,00%	110.556

Fonte: A Autora (2025).

Os 41,31 km² classificados como corte raso representam uma transformação territorial significativa na área estudada. Esta quantificação não é meramente aritmética, mas constitui uma métrica biofísica concreta da pressão antrópica sobre o território


paraense. Cada km² convertido corresponde a perdas de biodiversidade, emissões de carbono e alterações nos serviços ecossistêmicos.

A distribuição espacial das áreas classificadas revela padrões morfológicos característicos que dialogam com os processos socioeconômicos subjacentes:

1. Polígonos de grande extensão com bordas geométricas, correspondem a conversão para agropecuária extensiva, onde a eficiência produtiva impõe uma lógica espacial à paisagem. Estas formas refletem a racionalidade econômica do agronegócio, que maximiza área cultivável enquanto minimiza perímetro (e, consequentemente, custos com cercas e manutenção).

2. Padrões lineares dendríticos, sugerem a presença de estradas não-oficiais que funcionam como veias de acesso para a floresta remanescente. Estas estruturas, frequentemente precursoras de futuros desmatamentos, materializam o que Hecht (2011) denomina infraestruturas de ocupação – vias que antecipam e facilitam a expansão da fronteira agrícola. Como visto a seguir:

Figura 12 - Distribuições espaciais encontradas pelo modelo.



Fonte: A Autora (2025).

Ademais, a fragmentação progressiva permite observar um gradiente espacial onde áreas maiores de floresta contínua são progressivamente reduzidas e isoladas por avanços convergentes da fronteira. Este padrão é particularmente preocupante por seus impactos ecológicos, incluindo efeito de borda, perda de conectividade e redução da resiliência ecossistêmica.

Com certeza, a escolha de Altamira como área para testar o modelo já treinado foi estrategicamente significativa, uma vez que o município figura consistentemente entre os mais desmatados da Amazônia Legal, apresentando características que o tornam um microcosmo das dinâmicas territoriais paraenses, como o histórico de conflitos fundiários com sobreposição de terras indígenas, unidades de conservação, assentamentos rurais e propriedades privadas de diversos portes (Beckmam et al., 2024).

Em adição, a presença de uma mega infraestrutura no município, como a Usina Hidrelétrica de Belo Monte, a qual está entre as maiores do Brasil, gerou transformações profundas na dinâmica populacional, econômica e territorial da região, com efeitos indiretos sobre o desmatamento. Além disso, a fronteira agropecuária ativa localizada no eixo da BR-163 (Cuiabá-Santarém), situa Altamira no corredor de expansão do agronegócio amazônico, sujeita a intensa pressão por conversão de florestas em pastagens e áreas agrícolas.

Isso posto, corrobora-se que os padrões espaciais identificados nos produtos digitais (Figura 10, 11 e 12) devem, portanto, serem lidos não como meras formas geométricas, mas como inscrições territoriais destas dinâmicas socioeconômicas complexas. Pois, cada polígono de corte raso representa o ponto final visível de processos que envolvem decisões econômicas, disputas por terra, políticas públicas (ou sua ausência) e relações de poder.

5.5 Limitações técnicas e metodológicas

A pequena diferença entre a acurácia no treinamento (99,30%) e no teste (98,37%), apenas 0,93% indicam baixo *overfitting*, validando a eficácia dos mecanismos de regularização intrínsecos ao Random Forest (*bagging* e seleção aleatória de variáveis). No entanto, duas limitações temporais importantes devem ser reconhecidas.

Como a sazonalidade restrita, o modelo foi treinado e testado exclusivamente com imagens do período seco (julho), quando as assinaturas espectrais do desmatamento são mais evidentes, já sua performance no período chuvoso, quando a floresta apresenta maior vigor vegetativo e a cobertura de nuvens é mais frequente, permanece não testada, há também, a janela temporal estreita, na qual a validação temporal limitou-se a 7 dias (entre as imagens de treino em 23/07/2024 e teste em 30/07/2024).

Embora tenha demonstrado consistência neste curto intervalo, não há evidências sobre sua performance em escalas temporais mais amplas (meses ou anos). Além disso, a excelência das métricas técnicas não deve obscurecer as limitações constitutivas do conhecimento produzido por sistemas baseados em sensoriamento remoto óptico:

1. Cegueira noturna, o modelo é insensível a dinâmicas de desmatamento que ocorrem predominantemente à noite uma estratégia documentada de evasão à fiscalização em algumas regiões amazônicas.

2. Opacidade social, classifica pixels, não processos sociais, ou seja, não distingue entre desmatamento legal e ilegal, entre pequenos produtores e grandes empresas, entre conversão para subsistência e para agroexportação.

3. Historicidade, captura um estado instantâneo (30/07/2024) sem incorporar as trajetórias históricas que levaram àquela configuração territorial. Não revela, por exemplo, se um polígono de corte raso é uma conversão recente de floresta primária, secundária ou a reativação de uma área abandonada há décadas.

4. Dicotomia simplificadora, reduz a sucessão de estados florestais (floresta primária → degradada → secundária → corte raso) a uma dicotomia binária, tornando invisíveis estágios intermediários de transformação que podem ser igualmente importantes para políticas de conservação.

A partir disso, é importante distinguir entre as limitações técnicas, que são passíveis de correção e aprimoramento em iterações futuras, e as fronteiras epistemológicas, que são inerentes à própria natureza da abordagem, onde as primeiras, referem-se a aspectos como a restrição sazonal dos dados (apenas período seco).

A escala espacial do estudo piloto (99,50 km²) e a ausência de validação em campo independente lacunas que podem ser superadas com expansão temporal das imagens, aplicação em áreas mais extensas e parcerias para coleta de dados *in situ*.

Por isso, todo o *pipeline* desenvolvido está documentado em código Python reprodutível e *scripts* GEE comentados no github: <https://github.com/nadelly/O-uso-de-inteligencia-artificial-para-classificar-o-desmatamento-no-estado-do-Parana>.git, o que não apenas garante transparência metodológica, mas também facilita sua adaptação e melhoria contínua por outros pesquisadores ou órgãos técnicos (Gorelick et al., 2017).

O modelo é, portanto, uma ferramenta em evolução, aberta a refinamentos como a incorporação de dados de radar para contornar a cobertura de nuvens, a inclusão de variáveis topográficas ou socioeconômicas, e a comparação com algoritmos alternativos de *machine learning*.

Já as fronteiras epistemológicas dizem respeito aos limites constitutivos do conhecimento produzido por sensoriamento remoto óptico e classificação automatizada. Como discutido por Latour (1987) em sua análise das cadeias de referência na ciência, tecnologias de monitoramento operam por meio de traduções sucessivas que convertem fenômenos complexos como uma floresta em transformação em dados estáveis e administráveis.

Essa passagem necessariamente simplifica a realidade, privilegiando certos aspectos (assinaturas espectrais, padrões espaciais) em detrimento de outros (contextos sociais, históricos, noturnos). Sendo assim, o modelo classifica pixels, não processos; mapeia formas no espaço, mas não explica as motivações humanas, os conflitos fundiários ou as trajetórias históricas por trás de cada polígono de desmatamento.

Reconhecer essas fronteiras, como argumentam Daston e Galison (2007), não é sinal de falha, mas de maturidade científica uma admissão consciente de que todo instrumento de conhecimento ilumina certas dimensões da realidade enquanto deixa outras na sombra.

Nesse sentido, o modelo deve ser compreendido não como um retrato completo da dinâmica do desmatamento, mas como uma ferramenta especializada e parcial, cujo valor reside justamente em sua capacidade de produzir, com agilidade e baixo custo, informações acionáveis para a gestão territorial, desde que integrada a outras formas

de saber como o conhecimento local, os dados fundiários e as análises socioeconômicas.

6 CONCLUSÃO

A presente pesquisa teve como objetivo desenvolver e avaliar um modelo de classificação baseado no algoritmo Random Forest para a detecção de áreas de corte raso a partir de imagens de satélite no estado do Pará. A partir dos resultados obtidos, verifica-se que o objetivo geral do estudo foi alcançado, uma vez que o modelo demonstrou elevada capacidade de distinguir áreas de vegetação preservada e áreas de desmatamento a partir de padrões espectrais observados nos produtos de sensoriamento remoto.

Inicialmente, foi possível treinar o modelo Random Forest utilizando amostras espectrais extraídas de imagens Landsat 8 associadas a dados de referência provenientes do sistema PRODES. O processo de treinamento permitiu ao algoritmo identificar padrões característicos das classes analisadas, demonstrando a viabilidade do uso de técnicas de aprendizado de máquina aplicadas ao sensoriamento remoto para o monitoramento ambiental.

O desempenho do modelo foi avaliado por meio de métricas estatísticas amplamente utilizadas em problemas de classificação, incluindo acurácia, precisão, recall e F1-score. Os resultados obtidos indicaram um desempenho elevado do classificador, com acurácia global de aproximadamente 98%, evidenciando a eficiência do algoritmo na identificação das classes analisadas. A aplicação de validação cruzada também contribuiu para avaliar a robustez do modelo, indicando boa capacidade de generalização e reduzido risco de sobreajuste.

Posteriormente, o modelo treinado foi aplicado à classificação de uma área não utilizada no processo de treinamento, permitindo avaliar sua capacidade de reconhecer padrões espectrais em dados inéditos. O resultado da classificação gerou um mapa temático representando espacialmente a distribuição das áreas de corte raso e de vegetação, demonstrando o potencial da metodologia proposta para aplicações práticas em monitoramento ambiental.

A análise espacial dos resultados permitiu ainda identificar padrões de desmatamento compatíveis com processos antrópicos de conversão da cobertura

florestal, frequentemente associados à expansão de atividades agropecuárias. Tais padrões evidenciam a utilidade da abordagem baseada em aprendizado de máquina como ferramenta complementar aos sistemas tradicionais de monitoramento ambiental utilizados na Amazônia.

Além disso, o estudo também possibilitou refletir sobre os limites técnicos e metodológicos associados ao uso de inteligência artificial aplicada ao sensoriamento remoto. Embora algoritmos como o Random Forest apresentem elevada capacidade de processamento e classificação de grandes volumes de dados, sua aplicação depende diretamente de decisões humanas relacionadas à seleção das variáveis espectrais, definição das amostras de treinamento e interpretação dos resultados gerados.

Outro aspecto relevante do trabalho foi a documentação do *pipeline* metodológico utilizado no processo de classificação, incluindo o script desenvolvido em linguagem Python para treinamento, avaliação e aplicação do modelo. Essa documentação contribui para a transparência e reprodutibilidade da pesquisa, permitindo que outros pesquisadores ou instituições possam replicar e adaptar a metodologia proposta para diferentes áreas de estudo.

Dessa forma, conclui-se que o uso do algoritmo Random Forest associado a dados de sensoriamento remoto constitui uma abordagem eficiente, acessível e replicável para a identificação de áreas de corte raso na Amazônia. A metodologia proposta demonstra potencial para apoiar iniciativas locais de monitoramento ambiental, subsidiar ações de fiscalização e contribuir para a produção de informações estratégicas voltadas à conservação da floresta amazônica.

Como perspectiva para pesquisas futuras, recomenda-se ampliar o conjunto de variáveis espectrais utilizadas no modelo, incorporando índices adicionais derivados do sensoriamento remoto, como o NDFI (*Normalized Difference Fraction Index*), amplamente utilizado em estudos de monitoramento florestal na Amazônia por sua capacidade de capturar variações estruturais na vegetação.

Além disso, sugere-se o desenvolvimento de rotinas automatizadas em ambiente SIG, como no *software* QGIS, que permitam a vetorização automática dos *rasters* classificados gerados pelo modelo. Tal abordagem possibilitaria a conversão direta das áreas identificadas como corte raso em polígonos vetoriais, facilitando sua integração com bases cartográficas, análises espaciais e aplicações em processos de monitoramento e fiscalização ambiental.

REFERÊNCIAS

- ALENCAR, A. et al. Limitações e potencialidades do monitoramento de desmatamento na Amazônia: uma análise crítica dos sistemas PRODES e DETER. **Boletim do Museu Paraense Emílio Goeldi**. Ciências Naturais, v. 15, n. 3, p. 743-758, 2020.
- ALMEIDA, Claudio Aparecido de et al. Methodology for forest monitoring used in PRODES and DETER projects. São José dos Campos: **Instituto Nacional de Pesquisas Espaciais (INPE)**, 2021.
- ALSTON, L. J.; LIBECAP, G. D.; MUELLER, B. **Title, conflict, and land use: the development of property rights and land reform on the Brazilian Amazon frontier**. Ann Arbor: University of Michigan Press, 2000. 216 p.
- ASNER, G. P. Cloud cover in Landsat observations of the Brazilian Amazon. **International Journal of Remote Sensing**, v. 22, n. 18, p. 3855-3862, 2001.
- BALL, J. E. et al. A comprehensive review of Random Forest algorithm for remote sensing image classification. **International Journal of Applied Earth Observation and Geoinformation**, v. 112, 102869, 2022.
- DE ARAÚJO, Marlisson Lopes. Becker, Bertha K. Amazônia: geopolítica na virada do III milênio. **Ateliê Geográfico**, Goiânia, v. 5, n. 1, p. 269-275, 2011. Disponível em: <https://revistas.ufg.br/atelie/article/view/13835>. Acesso em: 22 jan. 2026.
- BECKMAN, W. F.; BRAGA, G. S.; CAMPEROS-REYES, J. T.; CONDURU, M. T. Dados abertos sobre áreas de desmatamento no estado do Pará. **Universidade e Meio Ambiente: Revista do Núcleo de Meio Ambiente da UFPA**, Belém, v. 9, n. 2, p. 60-70, 2024.
- BELGIU, Mariana; DRĂGUȚ, Lucian. Random forest in remote sensing: A review of applications and future directions. **ISPRS Journal of Photogrammetry and Remote Sensing**, [S. l.], v. 114, p. 24-31, abr. 2016. DOI: 10.1016/j.isprsjprs.2016.01.011. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0924271616000268>. Acesso em: 19 dez. 2024.
- BIRHANE, A. **The impossibility of automating ambiguity**. Artificial Life, v. 27, n. 1, p. 44-61, 2021.
- BRAGA JÚNIOR, Euclides de Oliveira. **Identificação de áreas com desmatamento seletivo em imagens multissensores - estudo de caso: sudoeste de Altamira-PA**. 2018. Artigo (Especialização em Geoprocessamento Ambiental), Instituto de Geociências, Universidade de Brasília, Brasília, 2018.
- BREIMAN, L. **Random forests**. Machine Learning, v. 45, n. 1, p. 5-32, 2001. DOI: 10.1023/A:1010933404324.
- BREIMAN, L. Random forests. **Machine Learning**, v. 45, p. 5-32, 2001.

BUNKER, S. G. **Underdeveloping the Amazon**: Extraction, Unequal Exchange, and the Failure of the Modern State. Chicago: University of Chicago Press, 1985. 296 p.

CRAWFORD, K. Atlas of AI: Power, Politics, and the Planetary Costs of Artificial Intelligence. **New Haven**: Yale University Press, 2021. 336 p.

CONGALTON, Russell G.; GREEN, Kass. **Assessing the accuracy of remotely sensed data**: principles and practices. 2. ed. Boca Raton: CRC Press, 2009.

Daston, L., & Galison, P. (2007). **Objectivity**. Zone Books.

MULTIPLE CLASSIFIER SYSTEMS, 2000, Berlin. Anais [...]. Berlin: Springer, 2000. p. 1-15. **Lecture Notes in Computer Science**, v. 1857.

D'IGNAZIO, C.; KLEIN, L. F. **Data Feminism**. Cambridge: MIT Press, 2020. 328 p.

EARTH RESOURCES OBSERVATION AND SCIENCE (EROS) CENTER. **Landsat 8-9 Operational Land Imager / Thermal Infrared Sensor Level-2, Collection 2**. [S. l.]: U.S. Geological Survey, 2020. Disponível em: <https://doi.org/10.5066/P9OGBGM6>. Acesso em: [01. jan. 2026].

FEARNSIDE, P. M. **Deforestation in Brazilian Amazonia**: History, rates, and consequences. *Conservation Biology*, v. 19, n. 3, p. 680-688, 2005.

FERRANTE, L.; FEARNSIDE, P. M. **Brazil's political upset threatens Amazonia**. *Science*, v. 371, n. 6527, p. 275-275, 2021.

GALVÃO, Jonilson Michel Fontes. **Classificação de regiões em imagens do satélite Sentinel-2 através de inteligência artificial**. 2023. Dissertação (Mestrado em Ciências Ambientais), Universidade Estadual Paulista "Júlio de Mesquita Filho", Sorocaba, 2023.

GOOGLE. USGS Landsat 8 Level 2, Collection 2, Tier 1. **Earth Engine Data Catalog**, 2026. Disponível em: https://developers.google.com/earth-engine/datasets/catalog/LANDSAT_LC08_C02_T1_L2. Acesso em: 10 jan.2026.

GORELICK, N. et al. Google Earth Engine: Planetary-scale geospatial analysis for everyone. **Remote Sensing of Environment**, [S. l.], v. 202, p. 18-27, 2017.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning**: Data Mining, Inference, and Prediction. 2. ed. New York: Springer, 2009. 745 p.

HOFFHINE, Emily F. **Forest Change Detection, Harvest and Cover Type Distinction Using Multiple Dates of Landsat Thematic Mapper**. 2000. 96 p. Dissertação (Mestrado em Ciências Florestais), Universidade do Maine, Orono, 2000.

INSTITUTO DO HOMEM E MEIO AMBIENTE DA AMAZÔNIA (IMAZON). **Ameaça e Pressão por Desmatamento na Amazônia Legal**: agosto de 2022 a julho de 2023. Belém: IMAZON, 2023. Disponível em: <https://imazon.org.br/imprensa/desmatamento->

na-amazonia-cresce-35-e-atinge-10-mil-km2-em-12-meses-aponta-imazon/. Acesso em: [02 jan. 2026].

INSTITUTO NACIONAL DE COLONIZAÇÃO E REFORMA AGRÁRIA (INCRA). **Relatório de Gestão e Exercício 2023**. Brasília, DF: INCRA, 2023. Disponível em: https://www.gov.br/incra/pt-br/acesso-a-informacao/transparencia-e-prestacao-de-contas/Relatorio_de_Gestao_do_Incra_2023_v26mar2024.pdf. Acesso em: [01 jan. 2026].

INSTITUTO NACIONAL DE PESQUISAS ESPACIAIS (INPE). **Projeto PRODES**: monitoramento da floresta amazônica brasileira por satélite. São José dos Campos: INPE, 2022.

INSTITUTO NACIONAL DE PESQUISAS ESPACIAIS (Brasil). **Metodologia utilizada nos sistemas PRODES e DETER** (2.^a ed., atualizada). São José dos Campos: INPE, 2022.

INSTITUTO NACIONAL DE PESQUISAS ESPACIAIS (INPE). **TerraBrasilis**: Plataforma de acesso a dados geográficos de monitoramento ambiental. São José dos Campos: INPE, 2024. 1 plataforma online. Disponível em: <https://terrabrasilis.dgi.inpe.br/>. Acesso em: [01 jan. 2026].

JENSEN, John R. **Remote sensing of the environment**: an earth resource perspective. 2. ed. Upper Saddle River: Pearson Education, 2009.

KUHN, M.; JOHNSON, K. **Applied Predictive Modeling**. Springer, 2013.

LAMBIN, Eric F. Monitoring forest degradation in tropical regions by remote sensing: some methodological issues. **Global Ecology and Biogeography**, v. 8, p. 191-198, 1999.

Latour, B. (1987). **Science in Action**: How to Follow Scientists and Engineers Through Society. Harvard University Press.

LILLESAND, Thomas M.; KIEFER, Ralph W.; CHIPMAN, Jonathan W. **Remote sensing and image interpretation**. 7. ed. Hoboken: John Wiley & Sons, 2015.

LIMA, T. A.; BEUCHLE, R.; LANGNER, A.; GRECCHI, R. C.; GRIES, V. C.; ACHARD, F. Comparing Sentinel-2 MSI and Landsat 8 OLI Imagery for Monitoring Selective Logging in the Brazilian Amazon. **Remote Sensing**, [S.l.], v. 11, n. 8, p. 961, 2019.

LORENZETT, C. D. C; TELOCKEN, A. V. Estudo Comparativo entre os algoritmos de Mineração de Dados Random Forest e J48 na tomada de Decisão. **Simpósio de Pesquisa e Desenvolvimento em Computação**, v. 2, n. 1, 2016.

MAPBIOMAS. MapBiomas Alertas: sistema de validação e refinamento de alertas de desmatamento. São Paulo: Projeto MapBiomas, 2023.

ORGANIZAÇÃO DAS NAÇÕES UNIDAS (ONU). **Transformando nosso mundo: a Agenda 2030 para o Desenvolvimento Sustentável**. Nova Iorque: ONU, 2015.

PEREIRA, A. A.; MELCHIORI, L. C.; SANTOS, J. R. Avaliação de índices espectrais para identificação de queimadas em áreas do Cerrado brasileiro. **Revista Brasileira de Cartografia**, v. 68, n. 8, p. 1665-1680, 2016.

PONZONI, F. J. et al. Caracterização dos estágios de degradação florestal utilizando dados orbitais: estudo de caso na região sul do estado do Pará. In: SIMPÓSIO BRASILEIRO DE SENSORIAMENTO REMOTO, 17., 2016, João Pessoa. **Anais eletrônicos [...]**. São José dos Campos: INPE, 2016. p. 2747-2754. Disponível em: <http://marte2.sid.inpe.br/col/sid.inpe.br/marte2/2016/07.07.12.35/doc/2747-2754.pdf>. Acesso em: [01 jan. 2026].

POWERS, David M. W. Evaluation: From Precision, Recall and F-Measure to ROC, Informedness, Markedness & Correlation. **Journal of Machine Learning Technologies**, [S. l.], v. 2, n. 1, p. 37-63, 2011.

PROBST, Philipp; BISCHL, Bernd; BOULSTEIX, Anne-Laure. Tunability: importance of hyperparameters of machine learning algorithms. **Journal of Machine Learning Research**, v. 20, n. 53, p. 1-32, 2019.

RAJÃO, R. et al. The rotten apples of Brazil's agribusiness. **Science**, v. 369, n. 6501, p. 246-248, 2020.

REYAEILZADEH, Payam; TANG, Lei; LIU, Huan. Cross-Validation. In: **Encyclopedia of Database Systems**. Boston, MA: Springer US, 2009. p. 532-538.

ROY, David P. et al. Web-enabled Landsat Data (WELD): Landsat ETM+ composited mosaics of the conterminous United States. **Remote Sensing of Environment**, [S. l.], v. 114, n. 1, p. 35-49, jan. 2010. Disponível em: <https://doi.org/10.1016/j.rse.2009.07.022>. Acesso em: [11 nov. 2025].

SASAKI, Y. The truth of the F-measure. **Teach Tutor Mater**, 2007. Disponível em: <https://www.aclweb.org/anthology/W07-2004.pdf>

SCHMINK, M.; WOOD, C. H. **Contested Frontiers in Amazonia**. New York: Columbia University Press, 1992. 387 p.

Scott, J. C. (1998). **Seeing Like a State**: How Certain Schemes to Improve the Human Condition Have Failed. Yale University Press.

SHIMABUKURO, Y. E. et al. The Brazilian Amazon Monitoring Program: PRODES and DETER Projects. In: ACHARD, F.; HANSEN, M. C. (Ed.). **Global Forest Monitoring from Earth Observation**. Boca Raton: CRC Press, 2013. p. 153-169.

SILVA, A. R. et al. Detecção de áreas florestais invariantes em séries temporais utilizando o algoritmo Random Forest. **Geographia**, Niterói, v. 23, n. 50, 2021.

SILVA JUNIOR, C. H. L. et al. The Brazilian Amazon deforestation rate in 2020 is the greatest of the decade. **Nature Ecology & Evolution**, [S. l.], v. 5, n. 2, p. 144-145, 2021.

SOUZA JR., Carlos M. et al. Reconstructing three decades of land use and land cover changes in Brazilian biomes with Landsat archive and Earth Engine. **Remote Sensing**, v. 12, 2020.

SOUZA, J. P. **Aplicação do algoritmo Random Forest para classificação do uso e cobertura da terra utilizando o Google Earth Engine**. 2022. Dissertação (Mestrado em Geografia), Universidade Federal de Campina Grande, Campina Grande, 2022.

STROBL, Carolin et al. Bias in random forest variable importance measures: illustrations, sources and a solution. **BMC Bioinformatics**, London, v. 8, n. 25, p. 1 21, 2007.

SUROWIECKI, J. **The Wisdom of Crowds**. New York: Doubleday, 2004.

SWAIN, P. H.; DAVIS, S. M. (Ed.). **Remote Sensing: The Quantitative Approach**. New York: McGraw-Hill, 1978.

TURNER, Frederick Jackson. **The Significance of the Frontier in American History**. Chicago: American Historical Association, 1893.

UNITED STATES GEOLOGICAL SURVEY (USGS). **Landsat missions: satellite data and information**. Reston: USGS, 2020.

VIEIRA, L. S.; QUEIROZ, G. R.; SHIGUEMORI, E. H. An analysis of the influence of the number of observations in a Random Forest time series classification to map the forest and deforestation in the Brazilian Amazon. **International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences**, [S. l.], v. XLIII-B3, p. 721-728, 2022.

ZHU, Zhe; WOODCOCK, Curtis E. Continuous change detection and classification of land cover using all available Landsat data. **Remote Sensing of Environment**, [S. l.], v. 144, p. 152-171, 2014.

ZHU, X. X. et al. Deep Learning in Remote Sensing: A Comprehensive Review and List of Resources. **IEEE Geoscience and Remote Sensing Magazine**, [S. l.], v. 5, n. 4, p. 8-36, 2017.

ZHU, Zhe; WOODCOCK, Curtis E. Object-based cloud and cloud shadow detection in Landsat imagery. **Remote Sensing of Environment**, [S. l.], v. 118, p. 83-94, mar. 2012.

APÊNDICES

APÊNDICE A - *Dataset.*

fid	class	Landsat8_2024-07-23_4	Landsat8_2024-07-23_5	Landsat8_2024-07-23_6	Landsat8_2024-07-23_7
1	1	9072	17926	15454	11338
2	1	9673	18528	17096	12397
3	1	8392	16859	13548	10124
4	1	9934	18424	17611	12812
5	1	9363	17837	15724	11649
6	1	9283	18993	15860	11583
7	1	9667	18153	17228	12503
8	1	9238	17896	15545	11507
9	1	9312	17549	15856	11720
10	1	9770	18930	16989	12358
11	1	9358	16999	15540	11670
12	1	9391	18121	16522	12022
13	1	9189	18577	15894	11680
14	1	8692	17203	14056	10632
15	1	9136	18431	15473	11301
16	1	8645	17554	13995	10453
17	1	9789	17486	16156	12071
18	1	8963	17411	15364	11208
19	1	9911	18582	16663	12245
20	1	9744	18368	17242	12524
21	1	9323	17385	15878	11723
22	1	9623	18793	17454	12503
23	1	8767	16819	14560	10881
24	1	8176	16105	12319	9590
25	1	10577	18508	18372	13406
26	1	8372	17136	13929	10270
27	1	9688	18329	16726	12266
28	1	9000	17270	15032	11255
29	1	9000	18535	15408	11246
30	1	9124	17972	15812	11536
31	1	9879	18752	17707	12789
32	1	8784	17765	14831	10852
33	1	9046	17553	15040	11085
34	1	9177	17344	15206	11351
35	1	9117	17540	15298	11335
36	1	9033	17817	15117	11220
37	1	8172	15776	11846	9309
38	1	8282	17842	13248	9855
39	1	9031	19091	15888	11468
40	1	8697	16880	13902	10410
41	1	9072	17816	15391	11367
42	1	9252	18586	16372	11832
43	1	8974	17629	14798	11025
44	1	9025	18488	15533	11365
45	1	9065	18921	15626	11394
46	1	8962	17992	15283	11205
47	1	9001	17804	15501	11328
48	1	9199	18077	15870	11613
49	1	9099	17636	15626	11506
50	1	9559	18408	15605	11555
51	1	9935	18581	17821	12929
52	1	10048	18918	18154	13096
53	1	8874	17071	14444	10937
54	1	8688	16306	14232	10702
55	1	9625	18741	16761	12164
56	1	8566	16585	13741	10359
57	1	9311	18090	16123	11754

APÊNDICE B - Script em Python para treinamento e aplicação do modelo Random Forest.

```
import os
import pandas as pd
import rasterio
import numpy as np
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import train_test_split
from sklearn.metrics import classification_report
import matplotlib.pyplot as plt
from matplotlib.colors import ListedColormap, BoundaryNorm
import matplotlib.patches as mpatches

# -----
# 1) Carregar amostra de treino
# -----
amostra_csv = "dados/amostras_indices.csv"
df = pd.read_csv(amostra_csv, sep=';')

print("Colunas do CSV:", df.columns)

# Separar atributos e classe
X = df.drop(columns=['fid', 'class'])
y = df['class']

# Guardar nomes das features para usar na predição
feature_names = X.columns.tolist()

# -----
# 2) Treinar Random Forest
# -----
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42, stratify=y
)

clf = RandomForestClassifier(
    n_estimators=100,
    random_state=42
)

clf.fit(X_train, y_train)

# Avaliação no conjunto de teste
y_pred = clf.predict(X_test)
print(classification_report(y_test, y_pred))

# -----
# 3) Classificar imagem Landsat
# -----
landsat_path = "dados/Landsat8_2024-07-30.tif"
output_path = "saidas/classificacao_rf.tif"

# Garantir que a pasta de saída existe
os.makedirs(os.path.dirname(output_path), exist_ok=True)

with rasterio.open(landsat_path) as src:
    bands = src.read()
    transform = src.transform
```

```

    crs = src.crs
    height = src.height
    width = src.width

print("Bands shape antes do ajuste:", bands.shape)

# Garantir apenas 7 bandas
if bands.shape[0] > 7:
    bands = bands[:7, :, :]

print("Bands shape após ajuste:", bands.shape)

# Converter para float32 antes dos cálculos
bands = bands.astype(np.float32)

# -----
# 4) Calcular índices com segurança
# -----
# Landsat 8 Level 2 Surface Reflectance:
# SR_B4 = Red
# SR_B5 = NIR
# SR_B6 = SWIR1
# SR_B7 = SWIR2

red = bands[3] # SR_B4
nir = bands[4] # SR_B5
swir1 = bands[5] # SR_B6
swir2 = bands[6] # SR_B7

den_ndvi = nir + red
den_ndmi = nir + swir1
den_nbr = nir + swir2

ndvi = np.divide(
    nir - red,
    den_ndvi,
    out=np.zeros_like(den_ndvi, dtype=np.float32),
    where=den_ndvi != 0
)

ndmi = np.divide(
    nir - swir1,
    den_ndmi,
    out=np.zeros_like(den_ndmi, dtype=np.float32),
    where=den_ndmi != 0
)

nbr = np.divide(
    nir - swir2,
    den_nbr,
    out=np.zeros_like(den_nbr, dtype=np.float32),
    where=den_nbr != 0
)

# Garantir que não há NaN ou infinito
ndvi = np.nan_to_num(ndvi, nan=0.0, posinf=0.0, neginf=0.0)
ndmi = np.nan_to_num(ndmi, nan=0.0, posinf=0.0, neginf=0.0)
nbr = np.nan_to_num(nbr, nan=0.0, posinf=0.0, neginf=0.0)

# -----

```

```

# 5) Empilhar bandas + índices
# -----
stack = np.stack([
    bands[0], bands[1], bands[2], bands[3], bands[4], bands[5], bands[6],
    ndvi, ndmi, nbr
])

n_bands, height, width = stack.shape
X_pred = stack.reshape(n_bands, -1).T

# Criar máscara para pixels válidos
mask_valido = np.any(stack != 0, axis=0).reshape(-1)

# Transformar em DataFrame com os mesmos nomes usados no treino
X_pred_df = pd.DataFrame(X_pred, columns=feature_names)

# Predição apenas para pixels válidos
y_pred_raster = np.zeros(height * width, dtype=np.uint8)
y_pred_raster[mask_valido] = clf.predict(X_pred_df.loc[mask_valido])

# Voltar ao formato raster
y_pred_raster = y_pred_raster.reshape(height, width).astype(np.uint8)

# -----
# 6) Salvar visualização PNG
# -----
preview_path = "saidas/preview_classificacao.png"

preview = y_pred_raster.astype(float).copy()
preview[~mask_valido.reshape(height, width)] = np.nan

# 0 = vegetação | 1 = corte raso
cores = ['#2E8B57', '#8B4513']
cmap = ListedColormap(cores)
norm = BoundaryNorm([-0.5, 0.5, 1.5], cmap.N)

plt.figure(figsize=(8, 8))
plt.imshow(preview, cmap=cmap, norm=norm)
plt.title('Classificação - Corte Raso', fontsize=12)
plt.axis('off')

leg_veg = mpatches.Patch(color='#2E8B57', label='Vegetação')
leg_cr = mpatches.Patch(color='#8B4513', label='Corte Raso')
plt.legend(handles=[leg_veg, leg_cr], loc='upper right')

plt.savefig(preview_path, dpi=300, bbox_inches='tight')
plt.close()

print("Visualização salva em:", preview_path)

# -----
# 7) Salvar raster classificado
# -----
profile_out = {
    'driver': 'GTiff',
    'height': height,
    'width': width,
    'count': 1,
    'dtype': rasterio.uint8,
    'crs': crs,

```



```

        'transform': transform,
        'nodata': 0
    }

    print("Tentando salvar em:", output_path)

    with rasterio.open(output_path, 'w', **profile_out) as dst:
        dst.write(y_pred_raster, 1)

        # adicionar descrição da banda
        dst.set_band_description(1, "Classificacao Corte Raso")

        # adicionar legenda das classes
        dst.update_tags(
            1,
            class_0="Vegetacao",
            class_1="Corte_Raso"
        )

    print("Classificação concluída e salva em:", output_path)

```

APÊNDICE C – Script para aquisição de imagens no Google Earth Engine.

```
// =====  
// Visualização lado a lado + Export automático  
// =====  
  
// --- 1) Ponto / AOI  
var point = ee.Geometry.Point([-52.18175834,-3.83010673]);  
var aoi = point.buffer(5000);  
  
// --- 2) Parâmetros de data e nuvem  
var startDate = '2024-01-01';  
var endDate = '2024-12-31';  
var cloudThreshold = 10;  
var maxToShow = 3; // quantas imagens mostrar lado a lado  
  
// --- 3) Buscar coleção Landsat 8 SR  
var colecao = ee.ImageCollection('LANDSAT/LC08/C02/T1_L2')  
  .filterBounds(aoi)  
  .filterDate(startDate, endDate)  
  .filter(ee.Filter.lt('CLOUD_COVER', cloudThreshold))  
  .sort('CLOUD_COVER');  
  
var count = colecao.size().getInfo();  
print('Imagens disponíveis:', count);  
  
if (count === 0) {  
  print('Nenhuma imagem encontrada com esses filtros.');} else {  
  var nShow = Math.min(maxToShow, count);  
  var lista = colecao.toList(nShow);  
  
  // --- 4) Função que prepara RGB para visualização  
  function prepararRGB(image) {  
    return ee.Image(image)  
      .select(['SR_B4','SR_B3','SR_B2'])  
      .multiply(0.0000275)  
      .add(-0.2);  
  }  
  
  // --- 5) Painel horizontal para os mapas  
  var mapsPanel = ui.Panel({  
    layout: ui.Panel.Layout.flow('horizontal'),  
    style: {stretch: 'horizontal'}  
  });  
  
  var titulo = ui.Label('Comparação RGB — selecione a imagem desejada visualmente',  
    {fontWeight: 'bold', fontSize: '14px', margin: '8px 0 8px 0'});  
  ui.root.clear();  
  ui.root.add(titulo);  
  ui.root.add(mapsPanel);  
  
  // --- 6) Loop para mostrar mapas e exportar imagens  
  for (var i = 0; i < nShow; i++) {  
    (function(i) {  
      var img = ee.Image(lista.get(i));  
      var dataStr = ee.Date(img.get('system:time_start')).format('YYYY-MM-dd').getInfo();  
      var imgRGB = prepararRGB(img).clip(aoi);
```

```

// Mapa individual
var map_i = ui.Map();
map_i.setOptions('SATELLITE');
map_i.centerObject(aoi, 10);
map_i.addLayer(imgRGB, {bands: ['SR_B4','SR_B3','SR_B2'], min:0, max:0.3, gamma:1.2}, 'RGB ' +
dataStr);

// Painel vertical
var subPanel = ui.Panel({
  widgets: [
    ui.Label('Data: ' + dataStr, {fontWeight: 'bold', margin: '4px 8px'}),
    map_i
  ],
  layout: ui.Panel.Layout.flow('vertical'),
  style: {width: (100 / nShow) + '%', margin: '0px 4px 0px 4px'}
});

mapsPanel.add(subPanel);

// --- 7) Exportar apenas bandas SR_B1 a SR_B7 (corrige erro de tipo)
var bandasExport = ['SR_B1','SR_B2','SR_B3','SR_B4','SR_B5','SR_B6','SR_B7'];

Export.image.toDrive({
  image: img.select(bandasExport).clip(aoi),
  description: 'Landsat8_' + dataStr,
  folder: 'EarthEngine',
  fileNamePrefix: 'Landsat8_' + dataStr,
  scale: 30,
  region: aoi,
  maxPixels: 1e13
});

})(i);
}
// --- 8) Sincronizar navegação dos mapas
var mapList = mapsPanel.widgets().map(function(w){ return w.widgets().get(1); });
var linker = ui.Map.Linker(mapList);
}

```